

RiskShip: Priorización Inteligente de Envíos con Riesgo de Falla

Solución con redes neuronales

Kevin Bueno S. y Lizeth Portela L.

Departamento de Ingeniería, Pontificia Universidad Javeriana

Bogotá D.C., Colombia

bueno.kevin@javeriana.edu.co, portelali@javeriana.edu.co

Resumen—RiskShip es un agente de priorización que estima el riesgo de pérdida de un envío en el momento de su creación, antes del despacho, y ordena los casos para que un equipo con capacidad limitada revise primero los más críticos. Este informe presenta la solución basada en redes neuronales sobre 262 317 registros históricos de envíos de Mercado Libre. El aporte central es el control de la fuga de información: se identificaron y descartaron columnas que reformulan la etiqueta, una fecha y una taxonomía de regiones que la codifican de forma silenciosa, y meses cuya etiqueta aún no había madurado. Con una partición temporal y cinco semillas, el modelo obtiene un PR-AUC de $0,750 \pm 0,002$ y un ROC-AUC de $0,824 \pm 0,002$ sobre un mes posterior al entrenamiento. Proyectado a la prevalencia real de cerca del 0,1 %, revisar el 1 % de los envíos capturaría el 30 % de las pérdidas, unas 30 veces más que una revisión al azar.

Palabras clave—redes neuronales, priorización de riesgo, logística, fuga de información, partición temporal, AutoML

I. INTRODUCCIÓN

Las plataformas de comercio electrónico operan redes logísticas en las que un envío atraviesa centros de *fulfillment*, *cross-docking*, transporte intermedio y última milla [1]. La capacidad humana de monitoreo es limitada, de modo que el valor de un modelo no está solo en clasificar bien, sino en concentrar la atención en la fracción de casos con mayor riesgo. Las redes neuronales ya se han usado para estimar riesgo de retraso en cadenas de suministro y mensajería [2], [3].

RiskShip se formula como un agente racional: observa los atributos del envío, estima un puntaje de riesgo entre 0 y 1, ordena los casos y recomienda cuáles revisar primero; la decisión final sigue siendo humana. Este informe cubre la primera de las cuatro técnicas previstas en el proyecto, las redes neuronales, y fija el protocolo experimental que compartirán las demás.

Alcance. La propuesta inicial consideraba envíos en curso, con variables de trazabilidad hasta un instante de corte, y como falla la pérdida o el retraso crítico. Esta primera validación se acotó a predecir la *pérdida* en el *momento de creación del envío*: es el punto donde una intervención es más barata y, en los datos disponibles, toda la línea de tiempo de estados es posterior a ese momento.

II. DATOS Y CONTROL DE LA FUGA DE INFORMACIÓN

El conjunto de datos unifica exportaciones de envíos de Mercado Libre: 262 317 filas y 58 columnas, con la etiqueta

binaria `is_lost` (24,3 % de positivos). Es una muestra de casos y controles: como la pérdida real ronda el 0,1 %, se conservaron las pérdidas y solo una fracción de los envíos sin pérdida. Cada fila es un *artículo* de un envío, no un envío: hay cerca de 246 000 envíos distintos y la etiqueta nunca difiere dentro de uno. Los identificadores de envío y de artículo no se usan como variables.

Como la predicción ocurre en la creación, solo es válida la información conocida en ese momento. El análisis exploratorio mostró que varias columnas de apariencia legítima codifican la etiqueta por la forma en que se extrajeron las dos clases. La Tabla I resume los hallazgos y la decisión tomada en cada caso.

Tabla I
FUENTES DE FUGA DE INFORMACIÓN Y DECISIÓN DE LIMPIEZA

Fuente	Evidencia	Decisión
Causa, clasificación y reembolso de la pérdida (9 columnas)	No nulas en el 100 % de las filas perdidas y en el 0 % del resto	Descartar
Línea de tiempo de estados	Posterior a la creación del envío	Descartar
DATEPARAMETER	Igual al inicio del envío si no se perdió; unos 9 días posterior si se perdió	Descartar
LG_REGION	La misma instalación recibe nombres de región distintos según la clase	Descartar
Nulos en peso, dimensión, valor o cantidad	Cerca del 100 % de esas filas están perdidas	Eliminar filas
Meses recientes	Tasa de pérdida de 0 % a 1,3 % frente a 31–47 % en los meses previos: la etiqueta aún no madura	Eliminar meses

Los meses válidos se calculan a partir de los datos: se conservan aquellos con ambas clases presentes y se descartan los meses finales cuya tasa de pérdida es inferior a la mitad de la mediana mensual. No se usa ninguna fecha absoluta como variable, solo el día de la semana, para que el modelo no reaprenda ese artefacto. Una auditoría de pureza revisa además, para cada variable categórica, qué proporción de filas cae en valores con tasa de pérdida extrema.

El conjunto limpio tiene 165 002 filas (de 2025-09 a 2026-03, 37 % de positivos) y 13 variables: seis categóricas (tipo de *picking*, instalación, dominio, categoría, marca y tipo de voluminoso), seis numéricas (peso, dimensión máxima, valor, cantidad de artículos, razón de servicio del mes anterior e indicador de voluminoso) y el día de la semana. La Fig. 1 muestra que la tasa de pérdida varía con fuerza entre instalaciones y poco entre los principales tipos de *picking*.

III. METODOLOGÍA

III-A. Modelo

Se usa AutoGluon-Tabular [4] restringido a sus dos motores de redes neuronales, sin árboles: un perceptrón multicapa en PyTorch (4 capas de 128 neuronas, ReLU, *dropout* de 0,1, optimizador Adam, tasa de aprendizaje de 3×10^{-4}) y el modelo tabular de fastai (capas de 200 y 100 neuronas, *dropout* de 0,1, tasa de aprendizaje de 10^{-2}). Ambos representan las variables categóricas con *embeddings* y se detienen de forma temprana según la validación. Sus salidas se combinan en un ensamble ponderado. Se usaron los hiperparámetros por defecto; AutoGluon gestiona internamente la imputación, la codificación y el escalado.

La métrica optimizada es la precisión promedio (PR-AUC) y no la exactitud, que resulta engañosa con clases desbalanceadas [5]: un modelo que siempre predijera “no perdido” ya acertaría en cerca de dos tercios de los casos.

III-B. Protocolo experimental

La partición es temporal (Tabla II): se entrena con los meses más antiguos y se valida y se prueba con los más recientes, de modo que ninguna información futura influye en el entrenamiento. Todas las filas de un envío comparten fecha de inicio, por lo que ningún envío queda repartido entre particiones; el notebook lo verifica.

Tabla II
PARTICIÓN TEMPORAL DE LOS DATOS LIMPIOS

Partición	Meses	Filas	Envíos	Positivos
Entrenamiento	2025-09 a 2026-01	125 082	112 303	39,0 %
Validación	2026-02	18 831	17 297	31,6 %
Prueba	2026-03	21 089	19 506	31,2 %

El entrenamiento se repite con cinco semillas (42 a 46). La partición y el conjunto de prueba son idénticos en todas las corridas; solo cambia el entrenamiento de las redes (inicialización de pesos, orden de los lotes y *dropout*). Se reportan la media y la desviación estándar muestral. El análisis detallado usa la semilla con mejor PR-AUC en *validación*, nunca en prueba.

Además de PR-AUC, ROC-AUC, exhaustividad (*recall*), precisión y F1 de la clase “perdido” con umbral 0,5, se miden Recall@ K y Precision@ K : al revisar solo el K % de los envíos con mayor puntaje, qué proporción de las pérdidas reales queda dentro de ese grupo y qué proporción de lo revisado era realmente una pérdida.

IV. RESULTADOS

La Tabla III muestra el desempeño sobre el mes de prueba. La referencia de PR-AUC para un orden aleatorio es la tasa de positivos, 0,312. La dispersión entre semillas es mínima, por lo que el resultado no depende de la semilla. Cada semilla se entrena en unos 100 s. En el modelo de referencia (semilla 46) la red de fastai alcanza un PR-AUC de 0,733, la de PyTorch 0,680 y el ensamble 0,749. Su matriz de confusión tiene 13 425 verdaderos negativos, 1 082 falsos positivos, 3 094 falsos negativos y 3 488 verdaderos positivos. La Fig. 2 muestra su curva de precisión-exhaustividad.

Tabla III
MÉTRICAS EN EL CONJUNTO DE PRUEBA (CINCO SEMILLAS)

Métrica	Media $\pm$ desviación
PR-AUC	0,7496 $\pm$ 0,0020
ROC-AUC	0,8241 $\pm$ 0,0020
Exhaustividad (umbral 0,5)	0,5339 $\pm$ 0,0136
Precisión (umbral 0,5)	0,7568 $\pm$ 0,0157
F1 (umbral 0,5)	0,6259 $\pm$ 0,0044
Tasa de falsos positivos (umbral 0,5)	0,0781 $\pm$ 0,0089
PR-AUC en validación	0,7644 $\pm$ 0,0019

IV-A. Calidad de la priorización

La Tabla IV mide la calidad del orden dentro de la muestra. Con alrededor de un tercio de positivos, ni un orden perfecto captura más de $K/0,312$ de las pérdidas al revisar el K %; el modelo queda cerca de ese techo hasta el 10 % revisado (Fig. 3).

Tabla IV
MÉTRICAS DE PRIORIZACIÓN EN PRUEBA (CINCO SEMILLAS)

K	Filas	Recall@ K	Techo	Precision@ K
1 %	211	0,032 $\pm$ 0,000	0,032	1,000 $\pm$ 0,000
5 %	1 054	0,158 $\pm$ 0,001	0,160	0,987 $\pm$ 0,004
10 %	2 109	0,302 $\pm$ 0,002	0,320	0,942 $\pm$ 0,006
20 %	4 218	0,506 $\pm$ 0,002	0,641	0,790 $\pm$ 0,004

IV-B. Proyección a la prevalencia real

Las Tablas III y IV describen el desempeño *dentro de la muestra*. En un diseño de casos y controles solo la exhaustividad y la tasa de falsos positivos (TFP) se trasladan sin cambios a la operación, porque cada una se calcula dentro de una sola clase; por eso el ROC-AUC es válido tal cual, mientras que la precisión, el PR-AUC y las métricas en K dependen de la prevalencia. Con prevalencia real π , para cualquier umbral:

$$f = \pi r + (1 - \pi) \text{TFP}, \quad p = \frac{\pi r}{f}, \quad (1)$$

donde r es la exhaustividad, f la fracción de envíos revisados y p la precisión. La Tabla V aplica la conversión al modelo de referencia con $\pi = 0,001$. Con puntaje mínimo de 0,78 se revisaría el 1 % de los envíos y se capturaría el 30 % de las pérdidas: una pérdida por cada 33 envíos revisados, 30 veces mejor que al azar. La proyección supone que los negativos de




Figura 1. Tasa de pérdida por tipo de *picking* y por instalación logística en los datos limpios. La línea punteada marca la tasa global.




Figura 2. Curva de precisión-exhaustividad del modelo de referencia en el conjunto de prueba. La línea punteada es la tasa de positivos.




Figura 3. Fracción de pérdidas capturadas según la fracción de casos revisados, frente al orden aleatorio y al orden perfecto.

la muestra representan a los reales, y π es una estimación del equipo, no un dato medido.

Tabla V
PROYECCIÓN A UNA PREVALENCIA REAL DE 0,1 % (MODELO DE REFERENCIA)

Puntaje mínimo	Exhaust.	TFP	Envíos revisados	Revisados por pérdida	Mejora sobre azar
0,91	0,159	0,0008	0,09 %	6	173
0,78	0,299	0,0097	1,00 %	33	30
0,53	0,507	0,0606	6,10 %	120	8,3
0,50	0,530	0,0746	7,50 %	142	7,1

IV-C. Importancia de variables

La Tabla VI muestra la importancia por permutación: la caída de PR-AUC al desordenar cada variable. Las variables restantes aportan menos de 0,005.

V. DISCUSIÓN Y LIMITACIONES

El muestreo es válido; la extracción por clase, no. Sobrerrepresentar las pérdidas es la práctica estándar ante un evento del 0,1 %. Los artefactos de la Tabla I no vienen de esa proporción, sino de que las dos clases se extrajeron por caminos distintos. Una nueva extracción debería usar una sola consulta para ambas clases (misma población, filtros, tablas y ventana de fechas de creación), submuestrear al azar solo los

Tabla VI
IMPORTANCIA POR PERMUTACIÓN (MODELO DE REFERENCIA)

Variable	Caída de PR-AUC
DOM_DOMAIN_ID (dominio del producto)	0,197
CANTIDAD_ITEMS	0,144
SHP_LG_FACILITY_ID (instalación)	0,070
PESO_TOTAL_KG	0,068
ORD_CATEGORY_NAME_L1 (categoría)	0,038
BRAND_NAME (marca)	0,018
PICKING_TYPE	0,017

negativos con una tasa registrada, incluir únicamente envíos con la etiqueta ya madura y tomar los atributos como estaban al crear el envío. Sin la tasa de muestreo, las probabilidades predichas no se pueden calibrar: sirven para ordenar, no como probabilidad de pérdida. Como la muestra ya tiene un tercio de positivos, no se aplicó ponderación de clases ni remuestreo.

Posible fuga residual en el dominio del producto. Precision@1 % es exactamente 1,0 en las cinco semillas, y los umbrales más altos de la Tabla V dependen de una TFP casi nula. Seis valores de DOM_DOMAIN_ID tienen 100 % de pérdida con 200 a 834 filas cada uno, y esa es la variable más importante del modelo. El patrón coincide con el artefacto de taxonomía hallado en LG_REGION y probablemente infla el tope del orden. Debe investigarse antes de tomar esa precisión como señal real.

Costo de una evaluación honesta. Una versión previa, con partición aleatoria y un mes de etiqueta inmadura, obtenía ROC-AUC de 0,848 y PR-AUC de 0,800. La caída a 0,824 y 0,750 es el precio de evaluar sobre envíos posteriores al entrenamiento, no un retroceso del modelo.

Otras limitaciones. El conjunto de prueba cubre un solo mes, así que mide la generalización al mes siguiente y no entre temporadas. Las métricas están a nivel de artículo, no de envío. No se exploraron de forma explícita capas, neuronas, activación ni regularización. Las semillas miden el ruido de entrenamiento, no la sensibilidad a la ventana temporal.

Consideraciones éticas. El puntaje puede reflejar sesgos históricos hacia ciertas instalaciones o categorías; expresa correlación, no causalidad, y se plantea como apoyo a la priorización humana, nunca como mecanismo automático de sanción.

VI. CONCLUSIONES Y TRABAJO FUTURO

Una red neuronal entrenada solo con información disponible en la creación del envío ordena el riesgo de pérdida de forma útil y estable: en un mes no visto, y proyectado a la prevalencia real, revisar el 1 % de los envíos capturaría cerca del 30 % de las pérdidas. El resultado más valioso del trabajo no es la métrica, sino el control de la fuga de información: sin él, el modelo habría reportado un desempeño casi perfecto aprendiendo artefactos de la extracción.

El trabajo inmediato es auditar DOM_DOMAIN_ID, explorar los hiperparámetros de la red y agregar las métricas a nivel de envío. El mismo protocolo (partición temporal, conjunto de prueba, semillas y métricas de priorización) se aplicará a las

técnicas restantes del proyecto: reglas evolucionadas con algoritmo genético, inferencia difusa y métodos de ensamble, para comparar desempeño, interpretabilidad y costo computacional.

REFERENCIAS

- [1] MercadoLibre, Inc., “Annual Report on Form 10-K for the fiscal year ended December 31, 2025,” U.S. Securities and Exchange Commission, feb. 2026.
- [2] M. Bortolini *et al.*, “A deep learning approach to predict supply chain delivery delay risk based on macroeconomic indicators: A case study in the automotive sector,” *Applied Sciences*, vol. 14, no. 11, art. 4688, 2024, doi: 10.3390/app14114688.
- [3] B. Ye, J. Zuo, X. Zhao y L. Luo, “Research on the express delivery delay prediction based on neural network in the background of big data,” en *Proc. 6th Int. Conf. Electronic, Mechanical, Information and Management Society*, 2016, pp. 1449–1454, doi: 10.2991/emim-16.2016.294.
- [4] N. Erickson *et al.*, “AutoGluon-Tabular: Robust and accurate AutoML for structured data,” arXiv:2003.06505, 2020.
- [5] T. Saito y M. Rehmsmeier, “The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets,” *PLoS ONE*, vol. 10, no. 3, art. e0118432, 2015.