RiskShip: Priorización Inteligente de Envíos con Riesgo de Falla

Solución con un sistema neuro-difuso (ANFIS)

Kevin Bueno S. y Lizeth Portela L.
Departamento de Ingeniería, Pontificia Universidad Javeriana
Bogotá D.C., Colombia
bueno.kevin@javeriana.edu.co, portelali@javeriana.edu.co

***Resumen*—RiskShip es un agente de priorización que estima el riesgo de pérdida de un envío en el momento de su creación, antes del despacho, y ordena los casos para que un equipo con capacidad limitada revise primero los más críticos. Este artículo presenta la tercera técnica del proyecto: un sistema de inferencia difusa adaptativo (ANFIS) de tipo Takagi-Sugeno, entrenado por gradiente en PyTorch sobre el mismo conjunto de datos, las mismas 13 variables, la misma partición temporal y el mismo protocolo de cinco semillas que la red neuronal (RNA) de referencia y que el clasificador simbólico evolucionado con programación genética (GP). Las variables categóricas entran como su tasa de pérdida suavizada, estimada solo en entrenamiento y fuera de pliegue por envío; los centros de las reglas se inicializan con *fuzzy c-means* y el número de reglas (32) se elige únicamente en validación. En el mes de prueba el ANFIS alcanza un PR-AUC de 0,753 $\pm$ 0,001 y un ROC-AUC de 0,823 $\pm$ 0,001, frente a 0,750 $\pm$ 0,002 y 0,824 $\pm$ 0,002 de la RNA y 0,639 $\pm$ 0,034 y 0,773 $\pm$ 0,019 del GP sobre el mismo *holdout*: iguala a la RNA con la menor dispersión entre semillas de las tres técnicas, entrena en unos 5 s por semilla y expone funciones de pertenencia y una base de reglas legibles. La importancia por permutación vuelve a señalar al dominio del producto (caída de PR-AUC de 0,247), lo que confirma que el artefacto de extracción sospechado condiciona a las tres técnicas por igual.**

***Palabras clave*—lógica difusa, ANFIS, Takagi-Sugeno, sistemas neuro-difusos, priorización de riesgo, logística, partición temporal, interpretabilidad**

I. Introducción

Las plataformas de comercio electrónico operan redes logísticas en las que un envío atraviesa centros de *fulfillment*, *cross-docking*, transporte intermedio y última milla. La capacidad humana de monitoreo es limitada, de modo que el valor de un modelo no está solo en clasificar bien, sino en concentrar la atención en la fracción de casos con mayor riesgo. En la literatura, el riesgo en cadenas de suministro se ha abordado con redes neuronales [1], [2], con métodos evolutivos [3], con mecanismos de votación [4] y, de forma recurrente, con lógica difusa [5], [6], por su capacidad de representar juicios graduales ("un envío pesado", "una instalación con historial malo") en lugar de umbrales duros. La Sección II amplía esta revisión hacia los sistemas neuro-difusos, la codificación de categóricas y la evaluación bajo desbalance.

RiskShip formula el problema como una clasificación binaria (el envío se pierde o no) resuelta a través de un puntaje continuo de riesgo que ordena los casos. La primera entrega del proyecto resolvió esa tarea con redes neuronales [7] y la segunda con programación genética [8]. Este artículo presenta la tercera técnica: un sistema de inferencia difusa adaptativo (ANFIS) [9] de tipo Takagi-Sugeno [10]. Un ANFIS es a la vez un sistema de reglas difusas y una red: cada regla tiene antecedentes gaussianos cuyos centros y anchos se aprenden por gradiente, y un consecuente lineal que propone un puntaje. A diferencia de la RNA, sus parámetros tienen un significado directo (el valor típico de cada variable para cada regla y cuánto tolera la regla alejarse de él); a diferencia del GP, el ajuste es determinista dada la semilla y no depende de una búsqueda combinatoria. La pregunta es si esa representación intermedia conserva la calidad de priorización de la red sin pagar la brecha que mostró el árbol simbólico.

Alcance. Igual que en las entregas anteriores, la tarea se acota a predecir la *pérdida* en el *momento de creación* del envío. El ANFIS se evalúa con el mismo protocolo que la RNA y el GP (misma limpieza, misma partición temporal, mismo conjunto de prueba, cinco semillas y mismas métricas) para que la comparación sea directa. Ni la RNA ni el GP se reentrenaron: sus cifras son las publicadas en el repositorio del proyecto.

II. Estado del arte

II-A. Sistemas de inferencia difusa y ANFIS

Los conjuntos difusos de Zadeh [11] permiten que un valor pertenezca en grado a una categoría lingüística, y un sistema de inferencia difusa combina reglas "SI–ENTONCES" sobre esas categorías. Takagi y Sugeno [10] propusieron reglas cuyo consecuente es una función lineal de las entradas, lo que convierte el sistema en una mezcla de modelos locales ponderada por el grado de activación de cada regla. Jang [9] mostró que un sistema Takagi-Sugeno puede escribirse como una red adaptativa de cinco capas (fuzzificación, activación, normalización, consecuentes y agregación) y entrenarse con un procedimiento híbrido: mínimos cuadrados para los consecuentes y descenso de gradiente para los antecedentes. Esa arquitectura, ANFIS, es la que adopta RiskShip, con dos adaptaciones habituales en clasificación: la salida pasa por una sigmoide y se entrena con entropía cruzada, de modo que los mínimos cuadrados ya no tienen solución cerrada y todos los parámetros se ajustan por gradiente con Adam [12]; y la

activación se calcula en logaritmos para que el producto de trece pertenencias no se anule numéricamente.

II-B. Diseño de reglas a partir de datos e interpretabilidad

Guillaume [13] revisa los métodos para inducir sistemas difusos a partir de datos y advierte que la precisión suele obtenerse a costa de la legibilidad: particiones que no se corresponden con etiquetas lingüísticas, reglas redundantes o que nunca se activan. Dos prácticas de esa revisión guían el diseño de RiskShip. La primera es inicializar las reglas con un agrupamiento difuso, el *fuzzy c-means* de Bezdek [14], de modo que cada regla nazca cubriendo una región real del espacio de entrada en lugar de una posición aleatoria que quizá nunca se active. La segunda es reportar la base de reglas resultante con etiquetas lingüísticas y con la cobertura efectiva de cada regla, para que la interpretabilidad se evalúe y no se suponga. Fernández *et al.* [15] estudian los clasificadores difusos lingüísticos con clases desbalanceadas y muestran que la granularidad de la partición y el tratamiento del desbalance determinan su comportamiento; aquí el desbalance se trata con una métrica de orden en la selección y la parada temprana, no con remuestreo. Rudin [16] sostiene que en decisiones de alto impacto debe preferirse un modelo interpretable a la explicación a posteriori de una caja negra; el ANFIS ocupa una posición intermedia, y este artículo la caracteriza en lugar de reclamarla.

II-C. Variables categóricas de alta cardinalidad

Un sistema difuso solo opera sobre entradas numéricas. Micci-Barreca [17] propuso codificar una categoría por su tasa objetivo suavizada hacia el previo global, con un peso que protege a las categorías raras de memorizar sus pocos casos. Prokhorenkova *et al.* [18] señalan el sesgo de esa codificación cuando se calcula con las mismas filas que luego se entrenan (la etiqueta de cada fila se filtra a su propia variable) y lo resuelven con estadísticas ordenadas, calculadas sin la fila en cuestión. RiskShip aplica la codificación de Micci-Barreca con la corrección de CatBoost en su forma fuera de pliegue, con pliegues por envío porque los artículos de un mismo envío comparten etiqueta y categorías.

II-D. Aprendizaje automático en riesgo logístico

Además de los trabajos citados en la introducción, la predicción de fallas en la última milla se ha abordado con aprendizaje supervisado: De Leeuw *et al.* [19] predicen la pérdida de paquetes sobre un año de envíos y recurren a explicabilidad a posteriori; Zhang *et al.* [20] proponen una red tabular para el retraso en comercio electrónico. La lógica difusa en riesgo logístico se ha usado sobre todo con reglas escritas por expertos [5], [6]; no se encontró un trabajo que aprenda un sistema difuso a partir de datos para la pérdida de envíos bajo un protocolo temporal, que es la aportación de este artículo.

II-E. Evaluación bajo desbalance y fuga de información

Davis y Goadrich [21] demuestran que una curva domina en el espacio ROC si y solo si domina en el espacio precisión-exhaustividad, y que este último es más informativo cuando la clase positiva es minoritaria; Saito y Rehmsmeier [22] lo confirman empíricamente. Kaufman *et al.* [23] formalizan la fuga de información como el uso de datos que no están legítimamente disponibles en el momento de la predicción. Ambas líneas sustentan el protocolo compartido de RiskShip: la precisión promedio como métrica principal y criterio de parada temprana, la partición temporal por mes, la codificación de categóricas calculada solo con entrenamiento y la exclusión de las columnas de la Tabla I.

III. Motivación y contextualización del problema

III-A. Problema de aplicación

La aplicación considera una operación logística de comercio electrónico. El equipo adoptó una prevalencia operacional de referencia del 0,1 % en la primera entrega [7]; es una estimación de contexto, no una estadística medida en este conjunto. Cada pérdida implica reembolso, reposición y deterioro de la confianza del comprador. El equipo que puede intervenir (verificar el empaque, reforzar el seguimiento, cambiar la ruta) tiene una capacidad fija, muy inferior al volumen diario. La pregunta operativa no es "¿se perderá este envío?" sino "¿cuáles de los envíos creados hoy merecen la atención disponible?". Un puntaje de riesgo que ordene los envíos la resuelve directamente.

Los datos disponibles son una muestra de casos y controles: se conservaron las pérdidas y solo una fracción de los envíos sin pérdida, de modo que la tasa de positivos de la muestra (24,3 % en bruto, 37 % tras la limpieza) no es la real. Esto condiciona qué métricas se trasladan a la operación (Sección IV-C).

III-B. Pregunta y objetivo

Para el módulo difuso la pregunta se concreta así: *¿puede un sistema neuro-difuso aprendido de los datos priorizar las pérdidas al nivel de la red neuronal y, al mismo tiempo, ofrecer una representación legible por reglas?* El objetivo es doble: (i) medir el desempeño de priorización del ANFIS sobre el mismo *holdout* temporal que la RNA y el GP, con cinco semillas y selección solo por validación; y (ii) caracterizar el modelo obtenido en número de reglas, cobertura y legibilidad de cada una, costo computacional y dependencia de la variable de dominio del producto, sobre la que pesa una sospecha de artefacto de extracción [7], [8].

IV. Descripción de la tarea

IV-A. Especificación

Entrada. Un registro de artículo de envío con las 13 variables conocidas en la creación: seis categóricas (`PICKING_TYPE`, `SHP_LG_FACILITY_ID`, `DOM_DOMAIN_ID`, `ORD_CATEGORY_NAME_L1`,

BRAND_NAME, TIPO_BULKY), seis numéricas (PESO_TOTAL_KG, DIM_MAX_CM, VALOR_TOTAL_USD, CANTIDAD_ITEMS, RATIO_SVC_MES_ANTERIOR, ES_BULKY) y el día de la semana derivado de date_status_0. Ninguna fecha absoluta es admisible: permitiría reaprender el sesgo de madurez de la etiqueta descrito abajo.

Salida. Un puntaje en $[0, 1]$, la sigmoide del logit agregado del sistema, que ordena los artículos; y una decisión binaria con umbral 0,5, el mismo punto operativo de la RNA. El puntaje está en la escala de la muestra y no es una probabilidad de producción.

Exclusiones por fuga de información. El análisis de la primera entrega [7] identificó columnas que no existen al crear el envío o que codifican la etiqueta por la forma en que se extrajeron las clases; el ANFIS hereda íntegramente esas exclusiones (Tabla I). Además se eliminan las filas con nulos en peso, dimensión, valor, cantidad o fecha de inicio (casi todas perdidas, un artefacto de extracción) y los meses recientes cuya etiqueta aún no ha madurado: se conservan los meses con ambas clases presentes y se descartan los finales cuya tasa de pérdida es inferior a la mitad de la mediana mensual. La función de limpieza del *notebook* del ANFIS es una copia literal de la del *notebook* de la RNA, de modo que los dos modelos ven exactamente las mismas filas.

Tabla I
FUENTES DE FUGA DE INFORMACIÓN HEREDADAS DEL PROTOCOLO RNA

Fuente	Motivo
Causa, clasificación y reembolso de la pérdida (9 columnas)	No nulas en el 100 % de las filas perdidas y en el 0 % del resto
status_0..10, date_status_1..10	Línea de tiempo posterior a la creación
DATEPARAMETER	Igual al inicio del envío si no se perdió; unos 9 días posterior si se perdió
LG_REGION	La misma instalación recibe nombres de región distintos según la clase
SHIPMENT_ID, ITE_ITEM_ID	Identificadores, no atributos

IV-B. Caracterización como agente racional y SMA

Con la plantilla PEAS, la *medida de desempeño* de RiskShip es la fracción de pérdidas reales que caen dentro del grupo revisado dada una capacidad fija (Recall@K), junto con el costo de los falsos positivos; su *entorno* es el flujo de envíos recién creados, parcialmente observable (solo los 13 atributos de la especificación son visibles), estocástico y secuencial; sus *actuadores* son la lista ordenada y la marca de "revisar" que recibe el equipo humano, que conserva la decisión final; y sus *sensores* son los atributos del envío en la creación.

En la arquitectura del proyecto el puntaje no lo produce un único modelo, sino un conjunto de agentes evaluadores (la RNA, el GP y ahora el ANFIS) que comparten entrada y contrato de salida, de modo que un coordinador pueda consultarlos, compararlos o combinarlos, y un agente humano cierre el ciclo revisando casos y realimentando etiquetas. En ese sistema multiagente (SMA) el módulo ANFIS es el evaluador por reglas: puede mostrar al revisor qué regla dominó el puntaje de un envío y en qué términos lingüísticos se describe esa regla, una justificación distinta de la fórmula del GP y de las importancias a posteriori de la RNA.

IV-C. Alcance y restricciones

Las restricciones se mantienen iguales a las de las entregas anteriores. (a) **Nivel de artículo:** una fila es un artículo, no un envío (cerca de 246 000 envíos en 262 317 filas); las métricas son por artículo y ningún SHIPMENT_ID aparece en dos particiones. (b) **Casos y controles:** la exhaustividad, la tasa de falsos positivos y el ROC-AUC no dependen directamente de la prevalencia, pero su traslado a la operación requiere que el muestreo preserve las distribuciones de puntajes dentro de cada clase, supuesto que los artefactos de extracción ponen en duda. La precisión, el PR-AUC, Recall@K y Precision@K dependen de la prevalencia y describen solo la calidad del orden dentro de la muestra; la mejora sobre el azar nunca es comparable con producción, pues su techo es $1/\pi$, cerca de 3 en la muestra y cerca de 1 000 en producción. (c) **Puntaje sin calibrar:** la sigmoide acota el puntaje a $[0, 1]$ pero no lo convierte en una probabilidad de producción; el umbral 0,5 es el de la muestra. (d) ***Holdout* conocido:** el mes de prueba ya se había observado al evaluar la RNA y el GP; esta es una comparación con *holdout* fijo, no una validación ciega nueva. (e) **Regla de madurez retrospectiva:** la selección de meses usa las etiquetas del conjunto completo; define la cohorte, no es una política operativa validada.

V. SOLUCIÓN CON UN SISTEMA NEURO-DIFUSO

V-A. Codificación de las variables

Una función de pertenencia gaussiana necesita una entrada numérica sobre la que medir cercanía. Las seis categóricas y el día de la semana se convierten en su tasa de pérdida suavizada [17]:

$$\tilde{x}_c = \frac{n_c\,\bar{y}_c + m\,\bar{y}}{n_c + m}, \tag{1}$$

donde n_c y $\bar{y}_c$ son la cantidad de filas y la tasa de pérdida de la categoría c en entrenamiento, $\bar{y}$ la tasa global de entrenamiento y $m = 20$ el peso del previo. Las categorías no vistas en entrenamiento reciben $\bar{y}$. Dos fugas se cierran de forma explícita. Hacia validación y prueba, las tasas se estiman solo con entrenamiento. Dentro del entrenamiento, cada fila se codifica *fuera de pliegue*: con cinco pliegues agrupados por SHIPMENT_ID, la tasa que ve una fila se calcula con los otros cuatro pliegues, de modo que ni su propia etiqueta ni la de los artículos de su mismo envío entran en su variable [18].

Las numéricas de cola larga (PESO_TOTAL_KG, DIM_MAX_CM, VALOR_TOTAL_USD, CANTIDAD_ITEMS) pasan por $\log(1 + x)$ para que una gaussiana pueda cubrirlas sin que unos pocos valores extremos la estiren; los nulos residuales de las numéricas se rellenan con la mediana de entrenamiento. Al final las 13 columnas se estandarizan con media y desviación de entrenamiento. La Tabla II resume la cardinalidad y el rango de las tasas aprendidas; nótese que

el 20,9 % de las filas de prueba trae una marca no vista en entrenamiento y entra con el previo, mientras que las demás categóricas están cubiertas casi por completo.

Tabla II
CODIFICACIÓN DE LAS CATEGÓRICAS EN ENTRENAMIENTO

Variable	Categorías	Tasa mín.	Tasa máx.	No vistas[a]
PICKING_TYPE	4	0,031	0,398	0,0 %
SHP_LG_FACILITY_ID	94	0,024	0,944	0,0 %
DOM_DOMAIN_ID	2 764	0,202	0,982	0,4 %
ORD_CATEGORY_NAME_L1	61	0,059	0,591	0,0 %
BRAND_NAME	22 761	0,177	0,885	20,9 %
TIPO_BULKY	3	0,348	0,391	0,0 %
day_of_week	7	0,356	0,418	0,0 %

[a] Fracción de filas de prueba cuya categoría no aparece en entrenamiento.

V-B. Arquitectura

Con R reglas sobre $d = 13$ entradas, cada regla r tiene la forma "SI x_1 es $A_{r,1}$ Y … Y x_d es $A_{r,d}$ ENTONCES $y_r = \mathbf{a}_r^\top \mathbf{x} + b_r$" y la red la implementa en cinco capas [9]:

$$\mu_{r,i}(x_i) = \exp\Big(-\tfrac{1}{2}\big(\tfrac{x_i - c_{r,i}}{\sigma_{r,i}}\big)^2 \Big), \tag{2}$$

$$w_r = \prod_{i=1}^{d} \mu_{r,i}(x_i), \qquad \bar{w}_r = \frac{w_r}{\sum_{k=1}^{R} w_k}, \tag{3}$$

$$z = \sum_{r=1}^{R} \bar{w}_r \, (\mathbf{a}_r^\top \mathbf{x} + b_r), \qquad \hat{p} = \sigma(z). \tag{4}$$

La conjunción (3) usa la t-norma producto y se calcula como $\log w_r = -\frac{1}{2}\sum_i ((x_i - c_{r,i})/\sigma_{r,i})^2$, con lo que la normalización es una *softmax* sobre las reglas y el producto de trece pertenencias pequeñas no se anula. Los anchos se guardan en logaritmo para que sean siempre positivos. Todos los parámetros (centros, anchos, pesos y sesgos de los consecuentes, $40R$ en total: 1 280 con $R = 32$) se ajustan minimizando la entropía cruzada binaria de $\hat{p}$ con Adam [12] en PyTorch [24], tasa de aprendizaje 5×10^{-3} y lotes de 2 048 filas. El *notebook* verifica que $\sum_r \bar{w}_r = 1$ en cada fila.

V-C. Inicialización

Con centros al azar, muchas reglas nacen en regiones vacías del espacio de entrada y nunca se activan. Por eso los centros se inicializan con *fuzzy c-means* [14] ($m = 2$, 50 iteraciones) sobre una muestra de 20 000 filas de entrenamiento; los anchos, con la dispersión ponderada de cada grupo (mínimo 0,2 en la escala estandarizada); y el sesgo b_r de cada consecuente, con el logit de la tasa de pérdida ponderada de su grupo, de modo que cada regla arranca diciendo algo razonable sobre su región. Los pesos $\mathbf{a}_r$ parten de cero.

V-D. Entrenamiento, parada temprana y selección de reglas

Cada entrenamiento recorre hasta 60 épocas y evalúa la precisión promedio en validación al final de cada una; se conserva el estado de la mejor época y se detiene tras ocho épocas sin mejora. El número de reglas es el hiperparámetro estructural: pocas reglas dan un modelo casi lineal, muchas lo dejan memorizar. Se entrenó una vez por candidato $R \in \{8, 16, 32, 64\}$ con la semilla base y se eligió el de mayor PR-AUC en validación (Tabla III): 32 reglas, con 0,7655; el conjunto de prueba no intervino. Después se repitió el entrenamiento con $R = 32$ para las cinco semillas.

Tabla III
SELECCIÓN DEL NÚMERO DE REGLAS (SEMILLA 42, SOLO VALIDACIÓN)

Reglas	PR-AUC val.	Mejor época	Tiempo (s)
8	0,7595	56	4,1
16	0,7645	31	3,1
32	**0,7655**	36	4,8
64	0,7634	20	4,5

VI. VALIDACIÓN EXPERIMENTAL

VI-A. Datos y partición

Se usa el mismo conjunto unificado de la RNA: 262 317 filas y 58 columnas, con la etiqueta binaria is_lost. Tras los filtros de la Sección IV quedan 165 002 filas de 2025-09 a 2026-03. La partición es temporal (Tabla IV): los meses más antiguos entrenan y los dos más recientes validan y prueban. Todas las filas de un envío comparten fecha de inicio, de modo que ningún envío queda repartido entre particiones; el código lo verifica en cada ejecución.

Tabla IV
PARTICIÓN TEMPORAL DE LOS DATOS LIMPIOS (IDÉNTICA A LA DE LA RNA Y EL GP)

Partición	Meses	Filas	Envíos	Positivos
Entrenamiento	2025-09 a 2026-01	125 082	112 303	39,0 %
Validación	2026-02	18 831	17 297	31,6 %
Prueba	2026-03	21 089	19 506	31,2 %

VI-B. Protocolo

El protocolo replica el de la RNA: cinco semillas (42 a 46) sobre la misma partición, donde la semilla cambia solo el entrenamiento (muestra del *fuzzy c-means*, inicialización y orden de los lotes); media y desviación estándar muestral ($\mathrm{ddof} = 1$) sobre el mes de prueba; selección del número de reglas únicamente en validación, y análisis detallado con la semilla de mejor PR-AUC en validación, nunca en prueba. Las métricas son PR-AUC, ROC-AUC, exhaustividad, precisión, F1 y tasa de falsos positivos de la clase "perdido" en el umbral 0,5, y Recall@K y Precision@K para $K \in \{1, 5, 10, 20\}$ % con el mismo desempate estable de la RNA. A diferencia del GP, el ANFIS comparte con la RNA el umbral 0,5 sobre una salida sigmoide, de modo que exhaustividad, precisión y F1 sí son comparables entre ambos en el mismo punto operativo. Ni la RNA ni el GP se reentrenaron: sus cifras provienen de los informes anteriores [7], [8].

VI-C. Reproducibilidad

El *notebook* ejecutado, con todas las tablas y figuras, está versionado en el repositorio de RiskShip:

https://github.com/aristotekean/riskship-rna

bajo `notebooks/anfis_shipment_loss.ipynb`; la versión revisada es el commit `2b18f26`. El entorno registrado usa Python 3.12, PyTorch 2.10.0, scikit-learn 1.9.1 y pandas 2.3.3, fijados en `uv.lock`; PyTorch llega con la pila de AutoGluon de la RNA, así que no se agregó ninguna dependencia. Con el conjunto de datos original, la ejecución completa se lanza desde la raíz del repositorio con:

```
uv run jupyter nbconvert --to notebook \
  --execute --inplace \
  notebooks/anfis_shipment_loss.ipynb
```

Las variables de entorno `ANFIS_N_SEEDS`, `ANFIS_MAX_EPOCHS` y `ANFIS_RULE_GRID` permiten una prueba de humo, que no es un resultado reportable. Las figuras de este artículo se reconstruyen con `python papers/build_anfis_figures.py`, que copia las que exporta el *notebook* y dibuja la comparación a partir de las tablas publicadas; no entrena modelos. La ejecución completa tarda menos de un minuto en CPU.

VI-D. Resultados

Por semilla. La Tabla V muestra las cinco corridas con 32 reglas. El PR-AUC de prueba va de 0,7516 (semilla 44) a 0,7546 (semilla 46), un rango de 0,003; la mejor época oscila entre 26 y 52 y cada entrenamiento tarda entre 3,6 y 6,3 s. La semilla con mejor validación (44, PR-AUC 0,7676) resulta ser la de menor PR-AUC en prueba, lo que ilustra por qué la selección no debe mirar la prueba: con una dispersión de 0,001, el orden entre semillas en prueba no es informativo.

Agregado y comparación. La Tabla VI resume las tres técnicas sobre el mismo mes de prueba. El ANFIS obtiene un PR-AUC de $0{,}7529 \pm 0{,}0012$ y un ROC-AUC de $0{,}8231 \pm 0{,}0008$, frente a $0{,}7496 \pm 0{,}0020$ y $0{,}8241 \pm 0{,}0020$ de la RNA; la diferencia en PR-AUC (+0,0033) es del orden de la suma de ambas desviaciones y la de ROC-AUC ($-0{,}0010$) es menor que la desviación de la RNA, de modo que las dos técnicas empatan en calidad de orden. En el umbral común 0,5 el ANFIS tiene mayor exhaustividad (0,562 frente a 0,534), menor precisión (0,725 frente a 0,757) y F1 ligeramente mayor (0,633 frente a 0,626), con una tasa de falsos positivos de 0,097 frente a 0,078: sitúa su punto operativo un poco más hacia la exhaustividad que la RNA. Frente al GP, el ANFIS está 0,114 por encima en PR-AUC y 0,050 en ROC-AUC, con una dispersión 28 veces menor. La referencia de PR-AUC para un orden aleatorio es la tasa de positivos, 0,312.

Calidad del orden. Con cerca de un tercio de positivos, ni un orden perfecto captura más de $K/0{,}312$ de las pérdidas al revisar el K % (0,032, 0,160, 0,320 y 0,641). El ANFIS llega al 100 % de ese techo en el 1 % y el 5 %, al 97 % en el 10 % y al 78 % en el 20 %; la RNA, al 100 %, 99 %, 94 % y 79 %. Precision@1 % y Precision@5 % son exactamente 1,000 en las cinco semillas, con desviación cero: la cima del ranking está ocupada por filas que el modelo separa sin error alguno, lo que anticipa la discusión sobre el dominio.

Modelo de referencia. La semilla 44 (PR-AUC de validación 0,7676) es el modelo de referencia. En prueba obtiene PR-AUC 0,7516 y ROC-AUC 0,8220; su matriz de confusión en 0,5 tiene 13 140 verdaderos negativos, 1 367 falsos positivos, 2 913 falsos negativos y 3 669 verdaderos positivos. La Fig. 3 muestra su curva de ganancia. Proyectado a la prevalencia de referencia del 0,1 % con la exhaustividad y la tasa de falsos positivos de cada umbral, y bajo el supuesto de que los negativos muestreados representan a los reales, el umbral 0,5 revisaría el 9,5 % de los envíos para capturar el 56 % de las pérdidas (una pérdida real por cada 170 revisados, 5,9 veces el azar), y el puntaje que marca el 10 % superior de la muestra (0,890) revisaría el 0,48 % para capturar el 31 % (una por cada 15, 65 veces el azar). Los umbrales del 1 % y el 5 % superiores tienen tasa de falsos positivos cero en la muestra y proyectan una precisión de 1,0, una cifra que no debe leerse como real por el motivo que sigue.

Lectura difusa. La Fig. 2 muestra las funciones de pertenencia aprendidas por las 32 reglas para cada variable, en la escala estandarizada de entrenamiento. En las variables de alta importancia (`DOM_DOMAIN_ID`, `CANTIDAD_ITEMS`, `SHP_LG_FACILITY_ID`) las gaussianas se reparten en centros distintos y anchos estrechos; en las de baja importancia (`TIPO_BULKY`, `RATIO_SVC_MES_ANTERIOR`, `day_of_week`) se superponen en torno al origen con anchos grandes, es decir, casi no discriminan. La Tabla VII resume la base de reglas: cada regla se describe por la etiqueta lingüística de su centro en cada variable (*bajo*, *medio* o *alto* según el tercil de entrenamiento en que cae) y se mide por cuántas filas de prueba domina (es la regla de mayor activación) y qué tasa de pérdida tienen. Treinta de las 32 reglas dominan alguna fila; dos (11 y 30) ninguna, el "ruido" de reglas que Guillaume [13] describe. La regla 8 domina 1 562 filas con una tasa de pérdida de 0,957 y el mayor sesgo positivo (1,40): dominio de alta tasa histórica, valor y cantidad altos, voluminoso, *picking* de baja tasa. En el otro extremo, la regla 25 domina 2 231 filas con tasa 0,124 y el sesgo más negativo ($-2{,}46$): dominio y categoría de tasa media, cantidad alta, todo lo demás medio. Las reglas de mayor cobertura (5, 1, 6, 29 y 25, con 2 000 a 3 900 filas cada una) tienen tasas entre 0,12 y 0,29; el grueso de la prueba cae en reglas de riesgo bajo y la discriminación la hacen las reglas de cola.

Importancia por permutación. Barajar `DOM_DOMAIN_ID` en prueba reduce el PR-AUC del modelo de referencia en 0,247; `CANTIDAD_ITEMS`, en 0,090; `SHP_LG_FACILITY_ID`, en 0,080; `PESO_TOTAL_KG`, en 0,042; `BRAND_NAME`, en 0,040; las ocho restantes, en menos de 0,014 cada una (Fig. 4). El orden coincide con el de la RNA, donde el dominio costaba 0,197 [7], y con los términos de mayor coeficiente del árbol del GP [8].

Costo computacional. Los cinco entrenamientos finales y los cuatro de selección suman menos de 45 s en CPU (14 hilos), con 1 280 parámetros por modelo; la RNA tarda cerca de 100 s por semilla y el GP entre 50 y 85 s en sus

Tabla V
CORRIDAS CON 32 REGLAS: VALIDACIÓN, PRUEBA Y COSTO POR SEMILLA

	PR-AUC	Prueba							Mejor	Tiempo
Semilla	**val.**	**PR-AUC**	**ROC-AUC**	**Exhaust.**	**Precisión**	**F1**	**TFP**	**Recall@20 %**	**época**	**(s)**
42	0,7655	0,7524	0,8237	0,5635	0,7226	0,6332	0,0982	0,5000	36	4,7
43	0,7617	0,7536	0,8232	0,5583	0,7283	0,6321	0,0945	0,5032	26	3,6
44	**0,7676**	0,7516	0,8220	0,5574	0,7286	0,6316	0,0942	0,5029	52	6,3
45	0,7660	0,7520	0,8228	0,5726	0,7140	0,6355	0,1041	0,5024	28	3,8
46	0,7639	0,7546	0,8241	0,5567	0,7329	0,6328	0,0920	0,5065	35	4,5
Media	0,7649	0,7529	0,8231	0,5617	0,7253	0,6330	0,0966	0,5030	35,4	4,6
Desv. est.	0,0022	0,0012	0,0008	0,0067	0,0073	0,0015	0,0047	0,0023	10,2	1,1

Tabla VI
MÉTRICAS EN EL CONJUNTO DE PRUEBA, MEDIA ± DESVIACIÓN ESTÁNDAR SOBRE CINCO SEMILLAS (MISMO HOLDOUT TEMPORAL)

Métrica	**ANFIS**	**RNA**[a]	**GP**[a]
PR-AUC	0,7529 ± 0,0012	0,7496 ± 0,0020	0,6393 ± 0,0338
ROC-AUC	0,8231 ± 0,0008	0,8241 ± 0,0020	0,7734 ± 0,0186
Exhaustividad[b]	0,5617 ± 0,0067	0,5339 ± 0,0136	0,6732 ± 0,0408
Precisión[b]	0,7253 ± 0,0073	0,7568 ± 0,0157	0,5506 ± 0,0369
F1[b]	0,6330 ± 0,0015	0,6259 ± 0,0044	0,6039 ± 0,0129
Tasa de falsos positivos[b]	0,0966 ± 0,0047	0,0781 ± 0,0089	—
Recall@1 %	0,0321 ± 0,0000	0,0321 ± 0,0000	0,0270 ± 0,0034
Recall@5 %	0,1601 ± 0,0000	0,1581 ± 0,0006	0,1343 ± 0,0127
Recall@10 %	0,3107 ± 0,0007	0,3019 ± 0,0020	0,2595 ± 0,0172
Recall@20 %	0,5030 ± 0,0023	0,5060 ± 0,0024	0,4450 ± 0,0199
Precision@1 %	1,0000 ± 0,0000	1,0000 ± 0,0000	0,8427 ± 0,1061
Precision@5 %	1,0000 ± 0,0000	0,9873 ± 0,0038	0,8387 ± 0,0796
Precision@10 %	0,9696 ± 0,0021	0,9421 ± 0,0061	0,8099 ± 0,0537
Precision@20 %	0,7849 ± 0,0036	0,7895 ± 0,0037	0,6944 ± 0,0311

[a] Cifras publicadas en el repositorio; ni la RNA ni el GP se reentrenaron.
[b] ANFIS y RNA con umbral 0,5; GP con umbral de F1 óptimo en validación.

Tabla VII
REGLAS DE REFERENCIA (SEMILLA 44): ETIQUETA LINGÜÍSTICA DEL CENTRO EN LAS VARIABLES DE MAYOR IMPORTANCIA, COBERTURA Y TASA DE PÉRDIDA EN PRUEBA

Regla	**Dominio**	**Cant.**	**Instal.**	**Peso**	**Marca**	**Filas**	**Tasa**	b_r
8	alto	alto	medio	medio	medio	1 562	0,957	1,40
10	medio	alto	medio	medio	alto	1 153	0,670	−0,21
17	medio	alto	alto	bajo	alto	529	0,590	0,53
1	medio	alto	medio	alto	alto	2 816	0,292	−0,90
31	alto	bajo	medio	medio	alto	1 362	0,233	−1,34
5	bajo	bajo	medio	medio	bajo	3 860	0,215	−0,51
6	alto	bajo	medio	medio	medio	2 393	0,199	−1,02
29	bajo	bajo	medio	medio	alto	2 024	0,195	−1,08
25	medio	alto	medio	medio	medio	2 231	0,124	−2,46
3	alto	bajo	medio	alto	bajo	405	0,101	−1,08

Diez de las 30 reglas activas; la tabla completa de 32 reglas y 13 variables está en el *notebook*.

corridas sin intervalos anómalos. Las tres medidas provienen de máquinas y condiciones distintas y no constituyen un *benchmark* controlado.

VI-E. Figuras

La Fig. 1 resume la comparación en PR-AUC, ROC-AUC y Recall@20 % con la desviación estándar entre semillas como barra de error. Las Figs. 2, 3 y 4 las exporta el *notebook* ejecutado para el modelo de referencia; ninguna procede de una prueba de humo.

VII. IMPACTOS ÉTICOS Y SOCIALES

Correlación, no causalidad. Las variables de mayor peso son tasas históricas de pérdida por dominio, instalación y marca. Un puntaje alto no indica que la instalación o el vendedor sean responsables; refleja el historial agregado de una categoría. Que la regla dominante de un envío se describa como "dominio de alta tasa, instalación de tasa media" puede leerse, erróneamente, como un juicio sobre ese dominio o esa instalación. El agente se plantea como apoyo a la priorización humana y nunca como mecanismo automático de sanción a instalaciones, vendedores o transportistas.

Sesgo heredado y artefactos de extracción. Si la base histórica contiene artefactos, el modelo los reproduce con apariencia de evidencia. El caso de `LG_REGION` ya demostró que una taxonomía puede codificar la etiqueta; la sospecha equivalente sobre `DOM_DOMAIN_ID` (seis valores con 100 % de pérdida y 200 a 834 filas cada uno) explica con toda probabilidad la Precision@1 % y @5 % perfectas y la tasa de falsos positivos nula en esos umbrales: la codificación por tasa (1) asigna a esos dominios un valor cercano a 1 que ninguna otra fila alcanza, y una regla con centro alto en esa variable los separa sin error. La legibilidad del ANFIS lo hace visible (la regla 8 y la caída de 0,247 al permutar), pero no lo corrige; obliga a investigar el artefacto en la fuente antes de operar.

Confidencialidad y efecto sobre la revisión. Las tablas de codificación contienen instalaciones, dominios y marcas de la empresa; el *notebook* versionado muestra solo agregados (cardinalidades, rangos de tasas, etiquetas lingüísticas) y ningún identificador de envío. Además, una lista priorizada concentra la atención en una fracción de los envíos: con Recall@20 % de 0,503, la mitad de las pérdidas quedaría fuera de una revisión del 20 %, y el puntaje debe complementar, no sustituir, los controles existentes.

VIII. RESULTADOS Y CRITERIOS DE COMPARACIÓN

Desempeño predictivo. El ANFIS y la RNA empatan: +0,0033 de PR-AUC y −0,0010 de ROC-AUC, diferencias dentro de la dispersión entre semillas. El GP queda 0,114 y 0,050 por debajo del ANFIS. La mejor semilla del GP (PR-AUC 0,689) no alcanza a la peor del ANFIS (0,752).

Calidad de la priorización. En el 10 % superior el ANFIS captura algo más que la RNA (Recall@10 % de 0,311 frente a 0,302) con mayor precisión (0,970 frente a 0,942); en el 20 %

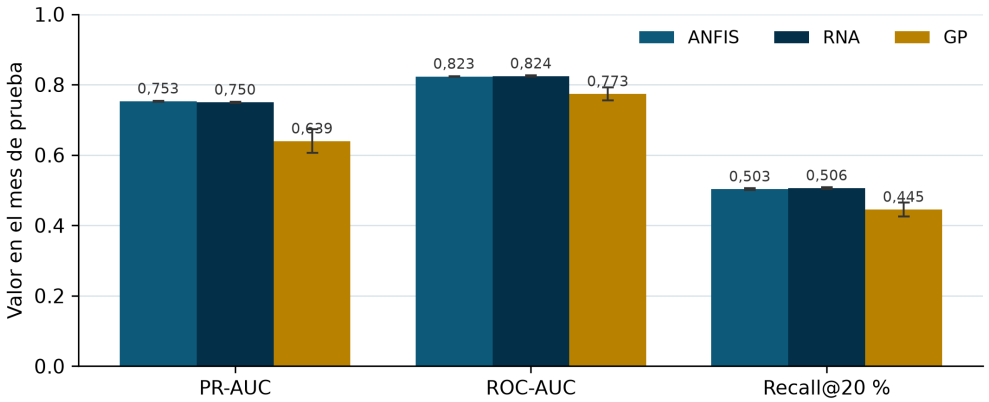


Figura 1. Comparación en el conjunto de prueba, por artículo: media y desviación estándar sobre cinco semillas del ANFIS, la RNA y el GP sobre el mismo mes de prueba. Las barras de error del ANFIS y la RNA son menores que el grosor de la línea.

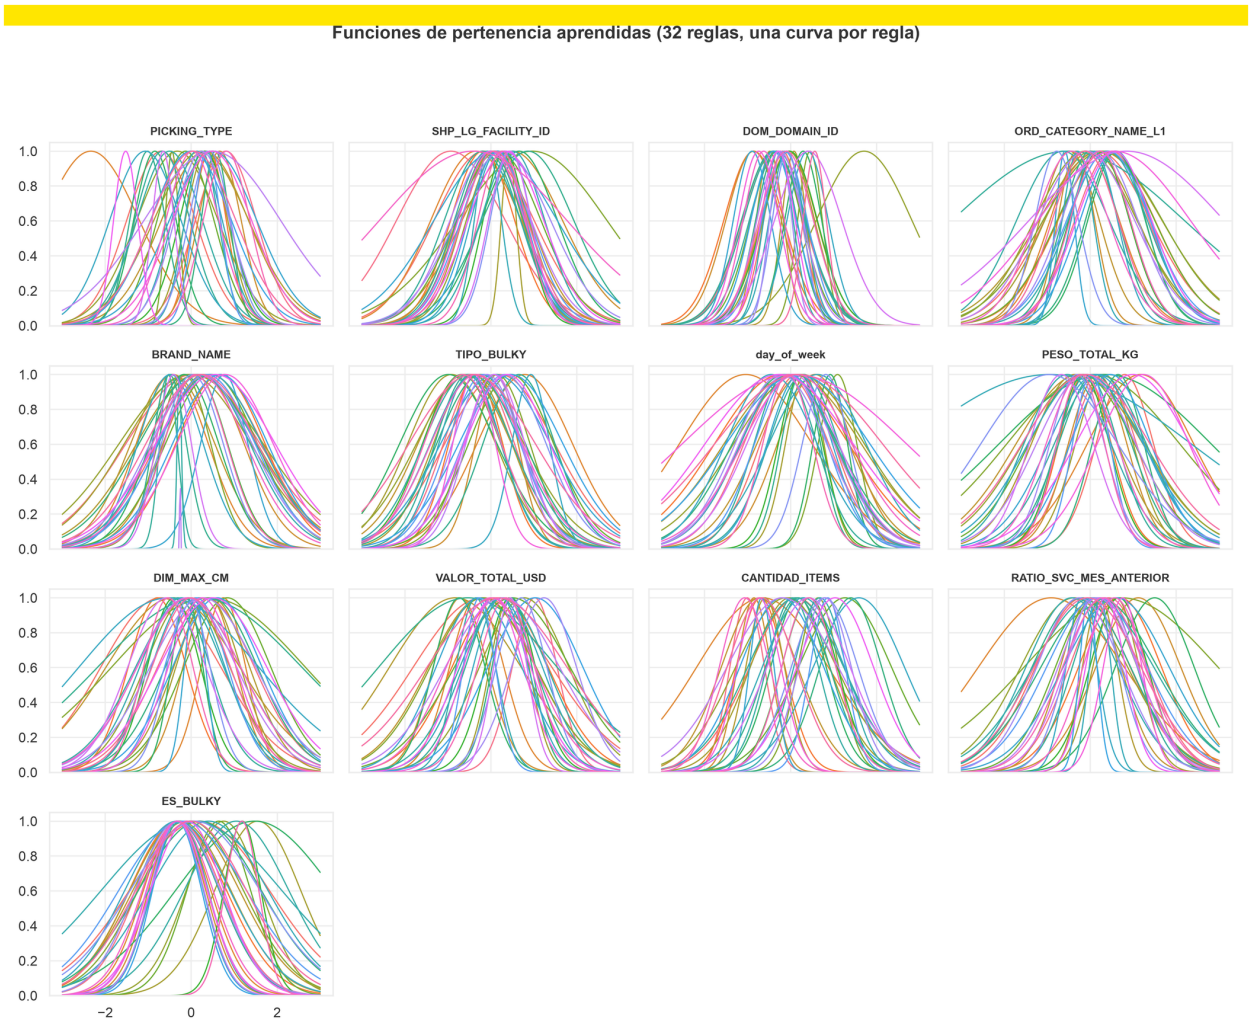


Figura 2. Funciones de pertenencia gaussianas aprendidas por el modelo de referencia (semilla 44, 32 reglas, una curva por regla) para cada variable, en la escala estandarizada de entrenamiento (0 es la media, ± 1 una desviación). Las categóricas aparecen ya codificadas por su tasa de pérdida (1), de modo que "alto" en una de ellas significa "categoría con alta tasa histórica", no una categoría concreta.

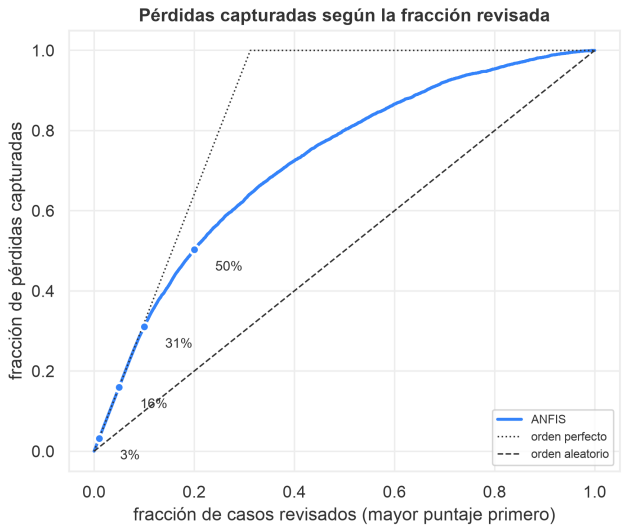


Figura 3. Pérdidas capturadas según la fracción revisada para el modelo de referencia en el mes de prueba. El orden perfecto está acotado por la tasa de positivos de la muestra (0,312).

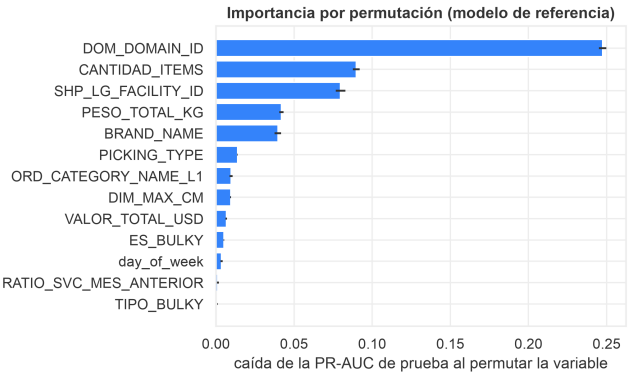


Figura 4. Importancia por permutación del modelo de referencia: caída de la PR-AUC de prueba al barajar cada variable (media y desviación sobre tres permutaciones). Mide dependencia, no causalidad.

la RNA recupera la ventaja por un margen mínimo (0,506 frente a 0,503). Ambas cimas están bajo la misma sospecha del artefacto de dominio, y la igualdad exacta de Recall@1 % en las dos técnicas (0,0321, el techo) sugiere que ocupan la cima con las mismas filas.

Interpretabilidad. El ANFIS ofrece una representación intermedia entre la fórmula del GP y la caja negra de la RNA: 32 reglas, cada una con 13 antecedentes gaussianos graficables y un consecuente lineal, y para cada envío una regla dominante con su etiqueta lingüística. Esa lectura tiene límites claros. Con 13 variables por regla, la base no se reduce a reglas cortas de libro; las categóricas entran ya codificadas, así que "marca alta" significa "marca de alta tasa histórica"; y las reglas de mayor cobertura son de riesgo bajo y poco diferenciadas, de modo que la explicación de un envío de riesgo alto depende de pocas reglas de cola. No se realizó una evaluación con usuarios que mida comprensión, tiempo de revisión o confianza, por lo que no se afirma una superioridad empírica en esas dimensiones.

Costo computacional. Unos 5 s por semilla y 1 280 parámetros, frente a cerca de 100 s de la RNA y a los 50 a 85 s del GP; sin GPU y sin AutoGluon. Son medidas de contexto, no un *benchmark* controlado, y una ventaja de velocidad de este orden solo importaría en reentrenamientos frecuentes.

Estabilidad entre semillas. El ANFIS es la técnica más estable de las tres (desviación de PR-AUC de 0,0012, frente a 0,0020 de la RNA y 0,0338 del GP). La inicialización con *fuzzy c-means* y el consecuente inicializado con la tasa de cada grupo explican en parte esa estabilidad: las cinco corridas parten de regiones parecidas del espacio de parámetros. Dos reglas inactivas en el modelo de referencia indican que 32 es un número holgado; la selección por validación no penalizó esa holgura.

Dependencia de `DOM_DOMAIN_ID`. Las tres técnicas dependen del dominio: caída de 0,247 en el ANFIS y 0,197 en la RNA al permutarlo, y 0,063 en el GP al retirarlo. La magnitud mayor en el ANFIS es coherente con una codificación que convierte los dominios puros en un valor extremo fácil de aislar con una gaussiana. La permutación mide dependencia, no causalidad, y no descarta que otras categóricas conserven una señal correlacionada.

IX. Conclusiones y trabajo futuro

Un sistema neuro-difuso de tipo Takagi-Sugeno, aprendido de los datos con información disponible solo al crear el envío y bajo el mismo protocolo temporal que la red neuronal y el clasificador simbólico, ordena el riesgo de pérdida al mismo nivel que la RNA (PR-AUC de 0,753 $\pm$ 0,001 frente a 0,750 $\pm$ 0,002; ROC-AUC de 0,823 frente a 0,824) y muy por encima del GP (0,639 y 0,773), con la menor dispersión entre semillas de las tres técnicas y un costo de entrenamiento de segundos. A cambio de la fórmula explícita del GP, entrega funciones de pertenencia graficables y una base de reglas con etiquetas lingüísticas y cobertura medida, que hace visible, sin corregirla, la dependencia del dominio del producto. La respuesta a la pregunta del módulo es afirmativa en desempeño y matizada en legibilidad: el ANFIS es tan competitivo como la RNA, y es más legible que ella, pero su base de 32 reglas sobre 13 variables codificadas no es una explicación de libro.

El resultado metodológico se mantiene: con la limpieza, la partición y las métricas copiadas literalmente del protocolo de la RNA, la selección del número de reglas solo en validación y cinco semillas, la comparación entre técnicas es directa y la igualdad observada es creíble. No prueba significancia ni generalización a otras cohortes: las desviaciones entre semillas no son intervalos de confianza poblacionales, y el mes de prueba ya era conocido. Una evaluación posterior podría estimar la incertidumbre de la diferencia ANFIS–RNA con remuestreo pareado por envío y probar meses nuevos.

El trabajo futuro inmediato es auditar `DOM_DOMAIN_ID` en la fuente, pues condiciona a las tres técnicas, y repetir el

ANFIS sin esa variable como ablación, igual que se hizo con el GP. Después: agrupar las marcas (por vendedor o categoría) para reducir el 21 % de filas de prueba que hoy entran con el previo; explorar los hiperparámetros apenas tocados (peso del previo, ancho mínimo, tasa de aprendizaje, pertenencias de campana generalizada o triangulares) siempre en validación; podar reglas inactivas o redundantes y regularizar los anchos para acercar la base a reglas legibles sin perder orden; y, como cierre del proyecto, evaluar un ensamble que combine la RNA, el ANFIS y el árbol simbólico con este mismo protocolo.

Referencias

[1] M. Bortolini *et al.*, "A deep learning approach to predict supply chain delivery delay risk based on macroeconomic indicators: A case study in the automotive sector," *Applied Sciences*, vol. 14, no. 11, art. 4688, 2024, doi: 10.3390/app14114688.

[2] B. Ye, J. Zuo, X. Zhao y L. Luo, "Research on the express delivery delay prediction based on neural network in the background of big data," en *Proc. 6th Int. Conf. Electronic, Mechanical, Information and Management Society*, 2016, pp. 1449–1454, doi: 10.2991/emim-16.2016.294.

[3] N. Nezamoddini, A. Gholami y F. Aqlan, "A risk-based optimization framework for integrated supply chains using genetic algorithm and artificial neural networks," *Int. J. Production Economics*, art. 107569, 2020, doi: 10.1016/j.ijpe.2019.107569.

[4] D. Wani, R. Singh, V. B. Khanapuri y M. K. Tiwari, "Delay prediction to mitigate e-commerce supplier disruptions using voting mechanism," *IFAC-PapersOnLine*, vol. 55, no. 10, pp. 731–736, 2022, doi: 10.1016/j.ifacol.2022.09.495.

[5] V. Gajović, M. Kerkez y J. Kočović, "Modeling and simulation of logistic processes: Risk assessment with a fuzzy logic technique," *Simulation*, vol. 94, no. 6, 2018, doi: 10.1177/0037549717738351.

[6] F. Aqlan y S. S. Lam, "A fuzzy-based integrated framework for supply chain risk assessment," *Int. J. Production Economics*, vol. 161, pp. 54–63, 2015, doi: 10.1016/j.ijpe.2014.11.013.

[7] K. Bueno S. y L. Portela L., "RiskShip: Priorización inteligente de envíos con riesgo de falla. Solución con redes neuronales," informe de proyecto, Pontificia Universidad Javeriana, Bogotá, 2026.

[8] K. Bueno S. y L. Portela L., "RiskShip: Priorización inteligente de envíos con riesgo de falla. Solución con programación genética," artículo de proyecto, Pontificia Universidad Javeriana, Bogotá, 2026.

[9] J.-S. R. Jang, "ANFIS: Adaptive-network-based fuzzy inference system," *IEEE Trans. Syst., Man, Cybern.*, vol. 23, no. 3, pp. 665–685, 1993, doi: 10.1109/21.256541.

[10] T. Takagi y M. Sugeno, "Fuzzy identification of systems and its applications to modeling and control," *IEEE Trans. Syst., Man, Cybern.*, vol. SMC-15, no. 1, pp. 116–132, 1985, doi: 10.1109/TSMC.1985.6313399.

[11] L. A. Zadeh, "Fuzzy sets," *Information and Control*, vol. 8, no. 3, pp. 338–353, 1965, doi: 10.1016/S0019-9958(65)90241-X.

[12] D. P. Kingma y J. Ba, "Adam: A method for stochastic optimization," en *Proc. 3rd Int. Conf. Learning Representations (ICLR)*, 2015, doi: 10.48550/arXiv.1412.6980.

[13] S. Guillaume, "Designing fuzzy inference systems from data: An interpretability-oriented review," *IEEE Trans. Fuzzy Syst.*, vol. 9, no. 3, pp. 426–443, 2001, doi: 10.1109/91.928735.

[14] J. C. Bezdek, *Pattern Recognition with Fuzzy Objective Function Algorithms*. Nueva York, EE. UU.: Plenum Press, 1981.

[15] A. Fernández, S. García, M. J. del Jesus y F. Herrera, "A study of the behaviour of linguistic fuzzy rule based classification systems in the framework of imbalanced data-sets," *Fuzzy Sets and Systems*, vol. 159, no. 18, pp. 2378–2398, 2008, doi: 10.1016/j.fss.2007.12.023.

[16] C. Rudin, "Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead," *Nature Machine Intelligence*, vol. 1, no. 5, pp. 206–215, 2019, doi: 10.1038/s42256-019-0048-x.

[17] D. Micci-Barreca, "A preprocessing scheme for high-cardinality categorical attributes in classification and prediction problems," *ACM SIGKDD Explorations Newsletter*, vol. 3, no. 1, pp. 27–32, 2001, doi: 10.1145/507533.507538.

[18] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush y A. Gulin, "CatBoost: Unbiased boosting with categorical features," en *Advances in Neural Information Processing Systems*, vol. 31, 2018, doi: 10.48550/arXiv.1706.09516.

[19] J. de Leeuw, Z. Bukhsh y Y. Zhang, "Parcel loss prediction in last-mile delivery: Deep and non-deep approaches with insights from explainable AI," preimpresión arXiv:2310.16602, 2023, doi: 10.48550/arXiv.2310.16602.

[20] Y. Zhang, Y. Wang y Y. Wang, "A deep tabular learning framework for e-commerce delivery delay prediction and cost-sensitive operational risk mitigation," *Algorithms*, vol. 19, no. 7, art. 597, 2026, doi: 10.3390/a19070597.

[21] J. Davis y M. Goadrich, "The relationship between precision-recall and ROC curves," en *Proc. 23rd Int. Conf. Machine Learning (ICML)*, 2006, pp. 233–240, doi: 10.1145/1143844.1143874.

[22] T. Saito y M. Rehmsmeier, "The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets," *PLoS ONE*, vol. 10, no. 3, art. e0118432, 2015.

[23] S. Kaufman, S. Rosset, C. Perlich y O. Stitelman, "Leakage in data mining: Formulation, detection, and avoidance," *ACM Trans. Knowl. Discov. Data*, vol. 6, no. 4, art. 15, pp. 1–21, 2012, doi: 10.1145/2382577.2382579.

[24] A. Paszke *et al.*, "PyTorch: An imperative style, high-performance deep learning library," en *Advances in Neural Information Processing Systems*, vol. 32, 2019, doi: 10.48550/arXiv.1912.01703.