RiskShip: Priorización Inteligente de Envíos con Riesgo de Falla

Solución con programación genética

Kevin Bueno S. y Lizeth Portela L.
Departamento de Ingeniería, Pontificia Universidad Javeriana
Bogotá D.C., Colombia
bueno.kevin@javeriana.edu.co, portelali@javeriana.edu.co

***Resumen*—RiskShip es un agente de priorización que estima el riesgo de pérdida de un envío en el momento de su creación, antes del despacho, y ordena los casos para que un equipo con capacidad limitada revise primero los más críticos. Este artículo presenta la segunda técnica del proyecto: un clasificador simbólico evolucionado con programación genética (GP) sobre el mismo conjunto de datos, las mismas 13 variables y la misma partición temporal que la red neuronal (RNA) de referencia. Los árboles, construidos con DEAP a partir de operaciones aritméticas protegidas sobre variables codificadas, se evalúan con la precisión promedio sobre las 125 082 filas de entrenamiento penalizada por tamaño; la configuración, el árbol y el umbral se eligen solo en validación y la selección se sella antes de puntuar la prueba. Con cinco semillas, el GP alcanza en el mes de prueba un PR-AUC de 0,639 $\pm$ 0,034 y un ROC-AUC de 0,773 $\pm$ 0,019, frente a 0,750 $\pm$ 0,002 y 0,824 $\pm$ 0,002 de la RNA sobre el mismo *holdout*: no la alcanza, pero produce expresiones de 9 a 36 nodos legibles. Una ablación sin el dominio del producto reduce el PR-AUC a 0,577 $\pm$ 0,016, lo que confirma la dependencia de una variable con un artefacto de extracción sospechado.**

***Palabras clave*—programación genética, regresión simbólica, priorización de riesgo, logística, partición temporal, interpretabilidad, DEAP**

I. Introducción

Las plataformas de comercio electrónico operan redes logísticas en las que un envío atraviesa centros de *fulfillment*, *cross-docking*, transporte intermedio y última milla [1]. La capacidad humana de monitoreo es limitada, de modo que el valor de un modelo no está solo en clasificar bien, sino en concentrar la atención en la fracción de casos con mayor riesgo. En la literatura, el riesgo en cadenas de suministro se ha abordado con redes neuronales [2], [7], con lógica difusa [4], [6], con mecanismos de votación [5] y con métodos evolutivos: Nezamoddini *et al.* [3] combinan un algoritmo genético con redes neuronales para optimizar una cadena integrada bajo riesgo. La Sección II amplía esta revisión hacia la programación genética, los datos tabulares y la evaluación bajo desbalance.

RiskShip formula el problema como una clasificación binaria (el envío se pierde o no) resuelta a través de un puntaje continuo de riesgo que ordena los casos. La primera entrega del proyecto resolvió esa tarea con redes neuronales [11]. Este artículo presenta la segunda técnica: programación genética (GP) [8], que evoluciona expresiones simbólicas cuya salida es el puntaje. A diferencia de una red, el resultado es una fórmula que puede leerse, auditarse y, si fuera necesario, calcularse a mano; a cambio, la búsqueda es estocástica y la capacidad de representación depende de las primitivas elegidas. La pregunta es si esa interpretabilidad se obtiene a un costo aceptable en calidad de priorización.

Alcance. Igual que en la entrega anterior, la tarea se acota a predecir la *pérdida* en el *momento de creación* del envío. El GP se evalúa con el mismo protocolo que la RNA (misma limpieza, misma partición temporal, mismo conjunto de prueba, cinco semillas y mismas métricas) para que la comparación sea directa. La RNA no se reentrenó: sus cifras son las publicadas en el repositorio del proyecto.

II. Estado del arte

II-A. Programación genética para clasificación con clases desbalanceadas

La programación genética evoluciona programas, habitualmente árboles de expresión, mediante selección, cruce y mutación [8]. Espejo *et al.* [12] revisan su aplicación a la clasificación y distinguen tres familias: árboles de decisión evolucionados, reglas y funciones discriminantes, que devuelven un valor numérico comparado con un umbral. Para clases desbalanceadas, Bhowan *et al.* muestran que la exactitud como aptitud sesga la búsqueda hacia la clase mayoritaria y proponen funciones de aptitud basadas en el área bajo la curva ROC y en la exactitud por clase [13], y después un enfoque multiobjetivo que evoluciona ensambles diversos a partir del frente de Pareto [14]. El clasificador de RiskShip pertenece a la familia de funciones discriminantes: el árbol devuelve un puntaje real, el umbral se fija aparte en validación y la aptitud es una métrica de orden (precisión promedio) en lugar de la exactitud, en línea con esa recomendación; la aptitud multiobjetivo de esos autores queda como trabajo futuro.

II-B. Control del tamaño e interpretabilidad

El crecimiento de los árboles sin ganancia de aptitud (*bloat*) es un problema clásico del GP. Luke y Panait [15] comparan de forma sistemática los métodos de control y concluyen que los límites estáticos de profundidad y las penalizaciones por tamaño (presión de parsimonia) figuran entre las técnicas más eficaces y sencillas; Poli *et al.* [16] recogen esa práctica como

estándar. Por su parte, Rudin [17] sostiene que, en decisiones de alto impacto, debe preferirse un modelo interpretable a la explicación a posteriori de una caja negra, y La Cava *et al.* [18] muestran en el banco de pruebas SRBench que los métodos de regresión simbólica basados en GP alcanzan una exactitud competitiva con modelos de caja negra con expresiones mucho más compactas. El GP de RiskShip combina ambas ideas: límites estáticos de altura 8 y 127 nodos junto con la penalización lineal $\lambda|T|$ de la aptitud, y el desempate por menor tamaño en la selección por validación; el resultado son árboles de 7 a 36 nodos que se reducen a sumas ponderadas legibles.

II-C. Redes neuronales frente a modelos de árbol y simbólicos en datos tabulares

En datos tabulares de tamaño medio, los modelos basados en árboles siguen superando a las redes neuronales profundas: Grinsztajn *et al.* [19] lo atribuyen a la robustez frente a variables no informativas y a la capacidad de representar funciones irregulares, y Shwartz-Ziv y Armon [20] comprueban que las arquitecturas profundas propuestas para datos tabulares rara vez superan a XGBoost fuera de los conjuntos en que fueron presentadas. Estos resultados no se trasladan directamente al GP, cuyas primitivas aritméticas continuas se parecen más a una red pequeña que a un árbol de decisión; la brecha de 0,110 en PR-AUC frente a la RNA sugiere que la limitación del GP de RiskShip no proviene del tipo de datos, sino del presupuesto de búsqueda y de la ausencia de primitivas condicionales, que es la hipótesis que motiva el trabajo futuro.

II-D. Aprendizaje automático en riesgo logístico y pérdida de envíos

Además de los trabajos sobre riesgo en cadenas de suministro citados en la introducción [2], [3], [5], la predicción de fallas en la última milla se ha abordado con aprendizaje supervisado. De Leeuw *et al.* [23] predicen la pérdida de paquetes sobre un año de envíos en Bélgica, donde la rareza de las pérdidas obliga a combinar balanceo de clases y ensambles, y recurren a técnicas de explicabilidad a posteriori; Zhang *et al.* [24] proponen una red tabular para el retraso en comercio electrónico y traducen las probabilidades en una simulación costo-beneficio de la intervención. El GP en logística se ha usado sobre todo para evolucionar políticas, como las reglas simbólicas de precios para ventanas de entrega de Lunet *et al.* [25], cuyo argumento (una política transparente y de cómputo trivial) coincide con el del módulo GP de RiskShip. No se encontró, en cambio, un trabajo que aplique GP a la clasificación de pérdida de envíos; la aportación de este artículo es evaluar esa combinación bajo un protocolo temporal compartido con la RNA.

II-E. Evaluación bajo desbalance y fuga de información

Davis y Goadrich [21] demuestran que una curva domina en el espacio ROC si y solo si domina en el espacio precisión-exhaustividad, y que este último es más informativo cuando la clase positiva es minoritaria; Saito y Rehmsmeier [10] confirman empíricamente que el ROC-AUC oculta diferencias relevantes en esos casos. Kaufman *et al.* [22] formalizan la fuga de información como el uso de datos que no están legítimamente disponibles en el momento de la predicción y muestran que su detección exige razonar sobre la cronología de cada atributo, no solo sobre su correlación con la etiqueta. Ambas líneas sustentan decisiones del protocolo de RiskShip: la precisión promedio como aptitud y métrica principal, la partición temporal por mes con los terminales de codificación objetivo calculados solo con meses anteriores, y la exclusión de las columnas de la Tabla I, entre ellas `DATEPARAMETER`, cuyo desfase según la clase es precisamente una fuga de las que esos autores describen.

III. Motivación y contextualización del problema

III-A. Problema de aplicación

Mercado Envíos gestiona un volumen de paquetes en el que la pérdida real ronda el 0,1 % de los envíos. Aunque la proporción es pequeña, cada pérdida implica reembolso, reposición y deterioro de la confianza del comprador. El equipo que puede intervenir (verificar el empaque, reforzar el seguimiento, cambiar la ruta) tiene una capacidad fija, muy inferior al volumen diario. La pregunta operativa no es "¿se perderá este envío?" sino "¿cuáles de los envíos creados hoy merecen la atención disponible?". Un puntaje de riesgo que ordene los envíos la resuelve directamente: el equipo revisa desde arriba hasta agotar su capacidad.

Los datos disponibles son una muestra de casos y controles: se conservaron las pérdidas y solo una fracción de los envíos sin pérdida, de modo que la tasa de positivos de la muestra (24,3 % en bruto, 37 % tras la limpieza) no es la real. Esto condiciona qué métricas se trasladan a la operación (Sección IV-C).

III-B. Pregunta y objetivo

La propuesta del proyecto planteó comparar varias técnicas de inteligencia artificial sobre un protocolo común. Para el módulo de programación genética la pregunta se concreta así: *¿puede un clasificador simbólico evolucionado priorizar las pérdidas de forma competitiva con la red neuronal y, al mismo tiempo, permanecer interpretable?* El objetivo es doble: (i) medir el desempeño de priorización del GP sobre el mismo *holdout* temporal que la RNA, con cinco semillas y selección solo por validación; y (ii) caracterizar el modelo obtenido en tamaño, variables usadas y costo computacional, incluida su dependencia de la variable de dominio del producto, sobre la que pesa una sospecha de artefacto de extracción [11].

IV. Descripción de la tarea

IV-A. Especificación

Entrada. Un registro de artículo de envío con las 13 variables conocidas en la creación: seis categóricas (`PICKING_TYPE`, `SHP_LG_FACILITY_ID`, `DOM_DOMAIN_ID`, `ORD_CATEGORY_NAME_L1`, `BRAND_NAME`, `TIPO_BULKY`), seis numéricas

(PESO_TOTAL_KG, DIM_MAX_CM, VALOR_TOTAL_USD, CANTIDAD_ITEMS, RATIO_SVC_MES_ANTERIOR, ES_BULKY) y el día de la semana derivado de date_status_0. Ninguna fecha absoluta es admisible: permitiría reaprender el sesgo de madurez de la etiqueta descrito abajo.

Salida. Un puntaje continuo de riesgo, no acotado ni calibrado, que ordena los artículos; y una decisión binaria obtenida al comparar ese puntaje con un umbral elegido en validación.

Exclusiones por fuga de información. El análisis de la primera entrega [11] identificó columnas que no existen al crear el envío o que codifican la etiqueta por la forma en que se extrajeron las clases; el GP hereda íntegramente esas exclusiones (Tabla I). Además se eliminan las filas con nulos en peso, dimensión, valor, cantidad o fecha de inicio (casi todas perdidas, un artefacto de extracción) y los meses recientes cuya etiqueta aún no ha madurado: se conservan los meses con ambas clases presentes y se descartan los finales cuya tasa de pérdida es inferior a la mitad de la mediana mensual.

Tabla I
FUENTES DE FUGA DE INFORMACIÓN HEREDADAS DEL PROTOCOLO RNA

Fuente	Motivo
Causa, clasificación y reembolso de la pérdida (9 columnas)	No nulas en el 100 % de las filas perdidas y en el 0 % del resto
status_0..10, date_status_1..10	Línea de tiempo posterior a la creación
DATEPARAMETER	Igual al inicio del envío si no se perdió; unos 9 días posterior si se perdió
LG_REGION	La misma instalación recibe nombres de región distintos según la clase
SHIPMENT_ID, ITE_ITEM_ID	Identificadores, no atributos

IV-B. Caracterización como agente racional y SMA

Con la plantilla PEAS, la *medida de desempeño* de RiskShip es la fracción de pérdidas reales que caen dentro del grupo revisado dada una capacidad fija (Recall@K), junto con el costo de los falsos positivos; su *entorno* es el flujo de envíos recién creados, parcialmente observable (solo los 13 atributos de la especificación son visibles), estocástico y secuencial; sus *actuadores* son la lista ordenada y la marca de "revisar" que recibe el equipo humano, que conserva la decisión final; y sus *sensores* son los atributos del envío en la creación.

En la arquitectura del proyecto el puntaje no lo produce un único modelo, sino un conjunto de agentes evaluadores (la RNA, el GP y las técnicas pendientes) que comparten entrada y contrato de salida, de modo que un coordinador pueda consultarlos, compararlos o combinarlos, y un agente humano cierre el ciclo revisando casos y realimentando etiquetas. En ese sistema multiagente (SMA) el módulo GP es el evaluador interpretable: su fórmula puede mostrarse al revisor como justificación del orden propuesto, algo que la red neuronal no ofrece directamente.

IV-C. Alcance y restricciones

Las restricciones se mantienen iguales a las de la RNA. (a) **Nivel de artículo:** una fila es un artículo, no un envío (cerca de 246 000 envíos en 262 317 filas); las métricas son por artículo y ningún SHIPMENT_ID aparece en dos particiones. (b) **Casos y controles:** solo la exhaustividad y la tasa de falsos positivos se trasladan a la operación sin cambios, por lo que el ROC-AUC es válido tal cual, mientras que la precisión, el PR-AUC, Recall@K y Precision@K dependen de la prevalencia y describen solo la calidad del orden dentro de la muestra; la mejora sobre el azar nunca es comparable con producción, pues su techo es $1/\pi$, cerca de 3 en la muestra y cerca de 1 000 en producción. (c) **Puntaje sin calibrar:** el árbol devuelve un real sin cota; sirve para ordenar y decidir con un umbral, no como probabilidad. (d) ***Holdout* conocido:** el mes de prueba ya se había observado al evaluar la RNA y una prueba inicial del GP; esta es una comparación con *holdout* fijo, no una validación ciega nueva. (e) **Regla de madurez retrospectiva:** la selección de meses usa las etiquetas del conjunto completo; define la cohorte, no es una política operativa validada.

V. SOLUCIÓN CON PROGRAMACIÓN GENÉTICA

V-A. Representación y primitivas

Cada individuo es un árbol de expresión de DEAP [9] cuya evaluación sobre un artículo produce el puntaje. Las hojas no son las columnas crudas, sino 19 terminales calculados solo con el conjunto de entrenamiento:

- **Codificación por frecuencia** de cada categórica (freq__*, 6 terminales): proporción de filas de entrenamiento con esa categoría; una categoría desconocida recibe cero.
- **Codificación objetivo temporal suavizada** de cada categórica (past_target__*, 6 terminales): tasa histórica de pérdida de la categoría con suavizado de 50 observaciones equivalentes hacia la tasa global. Para cada mes de entrenamiento solo se usan las etiquetas de los meses *anteriores* (el primer mes recibe 0,5), de modo que ningún artículo ve su propia etiqueta ni la de su mes; los artículos de un envío permanecen juntos. Validación y prueba usan los mapas de todo el entrenamiento.
- **Numéricas** (6) y **día de la semana** (1): imputación por la mediana, escalado por mediana y rango intercuartílico de entrenamiento y recorte a ± 30.

Los nodos internos se toman de diez primitivas: suma, resta, multiplicación, división protegida (un divisor con $|b| < 10^{-6}$ se sustituye por 1), mínimo y máximo, negación, valor absoluto, tangente hiperbólica y logaritmo protegido $\operatorname{sign}(a)\ln(1+|a|)$, más constantes efímeras uniformes en $[-1, 1]$. Cada operación acota su resultado a $\pm 10^6$ y sustituye los no numéricos por cero. La altura máxima es 8 y el tamaño máximo 127 nodos.

V-B. Operadores y parámetros evolutivos (DEAP)

La población inicial se genera con *ramped half-and-half* de profundidad 1 a 3 y sus primeros individuos se sustituyen por

los 19 terminales aislados, para que la evolución parta de líneas base simples. En cada generación se seleccionan $N-1$ padres por torneo de tamaño 4 y se aplica el esquema `varAnd` de DEAP: cruce de un punto con probabilidad 0,8 y mutación uniforme (sustitución de un subárbol por otro de profundidad 0 a 2) con probabilidad 0,2, de forma independiente, de modo que un hijo puede recibir ambos. El mejor individuo histórico pasa intacto a la generación siguiente (elitismo de uno). Los operadores llevan límites estáticos de altura y de nodos que rechazan al hijo que los supera; junto con la penalización por tamaño de la aptitud, es el control del *bloat*. Una caché por expresión evita recalcular árboles idénticos. La semilla fija el generador aleatorio y, con él, la población inicial y la secuencia de operadores.

V-C. Función de aptitud y tratamiento del desbalance

La aptitud de un árbol es la precisión promedio (PR-AUC) de su puntaje sobre las 125 082 filas de entrenamiento, sin submuestreo, menos una penalización lineal por tamaño:

$$\text{aptitud}(T) = \text{AP}_{\text{train}}(T) - \lambda\,|T|, \tag{1}$$

donde $|T|$ es el número de nodos. La precisión promedio es una métrica de orden adecuada para clases desbalanceadas [10]: no exige umbral y valora que las pérdidas queden arriba, que es el uso previsto del agente. La muestra ya contiene cerca de un tercio de positivos, por lo que, igual que en la RNA, no se aplica ponderación de clases ni remuestreo.

V-D. Configuraciones comparadas y selección por validación

Se fijó por adelantado un plan de tres configuraciones (Tabla II) que varían la codificación de las categóricas, el presupuesto evolutivo y λ. Cada una se ejecutó con las semillas 42 y 43 y se eligió la de mayor PR-AUC medio en *validación*; la ganadora se completó a cinco semillas (42 a 46) y se repitió cinco veces sin `DOM_DOMAIN_ID` como ablación. Dentro de cada corrida, el árbol final no es el de mejor aptitud de entrenamiento: se reúnen los campeones de entrenamiento de cada generación y los cinco mejores árboles finales, y se elige el de mayor PR-AUC en validación, con menos nodos como desempate. El umbral maximiza F1 de forma exacta sobre todos los puntos de la curva precisión-exhaustividad de validación, incluidos los empates de puntaje. Configuración, árboles y umbrales se guardaron en un archivo sellado antes de puntuar la prueba, que no intervino en ninguna elección.

Tabla II
CONFIGURACIONES COMPARADAS (PR-AUC EN VALIDACIÓN, MEDIA DE LAS SEMILLAS 42 Y 43)

Configuración	Codif.	Pobl.	Gen.	λ	AP val.
`frequency_100x15`	frec.	100	15	0,0001	0,5475
`temporal_130x18`	temp.	130	18	0,0001	0,5519
`temporal_180x25_regularized`	temp.	180	25	0,0003	**0,6061**

La configuración elegida fue `temporal_180x25_regularized`: codificación temporal, 180 individuos, 25 generaciones y $\lambda = 0{,}0003$. Una búsqueda con dos semillas por configuración no demuestra optimalidad; las cinco semillas posteriores cuantifican la variación del entrenamiento, no la incertidumbre por muestreo ni por selección de hiperparámetros.

VI. VALIDACIÓN EXPERIMENTAL

VI-A. Datos y partición

Se usa el mismo conjunto unificado de la RNA: 262 317 filas y 58 columnas, con la etiqueta binaria `is_lost`. Tras los filtros de la Sección III quedan 165 002 filas de 2025-09 a 2026-03. La partición es temporal (Tabla III): los meses más antiguos entrenan y los dos más recientes validan y prueban. Todas las filas de un envío comparten fecha de inicio, de modo que ningún envío queda repartido entre particiones; el código lo verifica en cada ejecución (cero grupos compartidos), junto con la forma del conjunto, los recuentos por partición y la consistencia de la etiqueta dentro de cada envío. La integridad del Parquet se comprobó con SHA-256.

Tabla III
PARTICIÓN TEMPORAL DE LOS DATOS LIMPIOS (IDÉNTICA A LA DE LA RNA)

Partición	Meses	Filas	Envíos	Positivos
Entrenamiento	2025-09 a 2026-01	125 082	112 303	39,0 %
Validación	2026-02	18 831	17 297	31,6 %
Prueba	2026-03	21 089	19 506	31,2 %

VI-B. Protocolo

El protocolo replica el de la RNA: cinco semillas (42 a 46) sobre la misma partición, donde la semilla cambia solo la búsqueda evolutiva; media y desviación estándar muestral ($\text{ddof} = 1$) sobre el mes de prueba; toda selección (configuración, árbol, umbral) únicamente en validación, y el análisis detallado con la semilla de mejor PR-AUC en validación, nunca en prueba. Las métricas son PR-AUC, ROC-AUC, exhaustividad, precisión y F1 de la clase "perdido" en el umbral elegido, y Recall@K y Precision@K para $K \in \{1, 5, 10, 20\}$ % con el mismo desempate estable de la RNA. Como un árbol simbólico puede empatar puntajes, se calculó además la esperanza exacta de Recall@K bajo desempate aleatorio en el límite; difiere de la tabla principal en menos de 0,0002 en todos los K. Una validación independiente recargó los diez modelos finales, reprodujo todas las métricas con tolerancia 10^{-12} y comprobó que permutar las etiquetas de prueba o introducir las columnas de fuga excluidas no altera los puntajes.

Dos diferencias con la RNA deben tenerse presentes. La RNA clasifica con umbral 0,5 sobre una probabilidad; el GP, con un umbral de F1 óptimo en validación sobre un puntaje sin calibrar, de modo que exhaustividad, precisión y F1 no comparten punto operativo y la comparación principal debe hacerse con PR-AUC, ROC-AUC y las métricas en K. Y la RNA no se reentrenó: sus cifras provienen del informe anterior [11].

VI-C. Resultados

Por semilla. La Tabla IV muestra cada corrida de la configuración elegida. Con dominio, el PR-AUC de prueba va de 0,597 (semilla 43) a 0,689 (semilla 44) y los árboles tienen entre 9 y 36 nodos; la semilla con mejor validación (44, PR-AUC 0,682) es también la mejor en prueba, aunque esa coincidencia no intervino en su elección. Sin dominio el rango es más estrecho (0,553 a 0,596) y ninguna semilla alcanza la peor con dominio.

Agregado y comparación con la RNA. La Tabla V resume las tres variantes sobre el mismo mes de prueba. El GP con dominio obtiene un PR-AUC de 0,6393 $\pm$ 0,0338 y un ROC-AUC de 0,7734 $\pm$ 0,0186, frente a 0,7496 $\pm$ 0,0020 y 0,8241 $\pm$ 0,0020 de la RNA; la referencia de PR-AUC para un orden aleatorio es la tasa de positivos, 0,312. El GP no alcanza a la RNA en ninguna métrica de orden, y su dispersión entre semillas es entre 9 y 17 veces mayor. Las métricas con umbral muestran el efecto del punto operativo distinto: el GP tiene mayor exhaustividad (0,673 frente a 0,534) y menor precisión (0,551 frente a 0,757), con F1 de 0,604 frente a 0,626. La ablación sin dominio reduce el PR-AUC medio en 0,0626 y el Recall@20 % de 0,445 a 0,399.

Calidad del orden. Con cerca de un tercio de positivos, ni un orden perfecto captura más de $K/0{,}312$ de las pérdidas al revisar el K % (0,032, 0,160, 0,320 y 0,641). El GP con dominio llega al 84 % de ese techo en el 1 % y al 69 % en el 20 %; la RNA, al 100 % y al 79 %. Precision@1 % del GP es 0,843 en media pero varía entre 0,763 y 1,000 según la semilla (la semilla 46 alcanza 1,000, como la RNA), lo que anticipa la discusión sobre el dominio.

Modelo de referencia. La semilla 44 (36 nodos, altura 8, umbral 1,134) es el modelo de referencia con dominio. Su expresión, con x_i los terminales de la Sección IV-A, es:

```
add(add(sub(sub(add(add(x8, sub(x8,
  x11)), x1), abs(x1)), x11), add(x7,
  add(add(x15, min(sub(sub(x7, x11),
  x11), x7)), sub(x10, x11)))),
  sub(add(x8, min(x14, x15)), x11))
```

donde x_8 y x_7 son la tasa histórica de pérdida del dominio y de la instalación, x_{10} y x_{11} la de la marca y del tipo de voluminoso, x_1 la frecuencia de la instalación, x_{15} la cantidad de artículos y x_{14} el valor. Salvo el recorte numérico de las operaciones protegidas, equivale a

$$s = 3x_8 + 2x_7 + x_{10} + x_{15} + \min(x_{14}, x_{15}) + 2\min(x_1, 0) - 4x_{11} - 2\max(x_{11}, 0), \quad (2)$$

una suma ponderada en la que el dominio tiene el mayor peso, seguido de la instalación; la cantidad de artículos y el valor entran de forma lineal y saturada, y el tipo de voluminoso con signo negativo. Doce de los 19 terminales no aparecen. En prueba, su matriz de confusión tiene 11 212 verdaderos negativos, 3 295 falsos positivos, 2 123 falsos negativos y 4 459 verdaderos positivos (PR-AUC 0,689, ROC-AUC 0,806). El modelo de referencia sin dominio (semilla 45, 9 nodos) es `sub(x6, sub(x5, add(add(x13, x1), x8)))`: con los terminales de esa variante, la tasa histórica de la instalación más su frecuencia, más la cantidad de artículos y la tasa histórica de la marca, menos la del tipo de *picking*; una regla lineal de cinco variables con PR-AUC de prueba 0,596.

Convergencia. En la semilla 44 la mejor aptitud parte de 0,608 con 3 nodos (generación 0), sube a 0,635 con 5 nodos (generación 2), a 0,667 con 20 nodos (generación 12) y a 0,719 con 36 nodos (generación 23), sin cambios en las dos últimas generaciones; la aptitud media de la población crece de 0,404 a 0,663. La corrida evaluó 2 724 expresiones distintas y reunió 17 candidatos para la selección por validación. La aptitud de entrenamiento del árbol elegido (0,729) supera su PR-AUC de validación (0,682) y de prueba (0,689).

Costo computacional. La suma de los tiempos de evolución y selección de las 14 corridas (6 de cribado, 5 finales y 5 de ablación) fue de 13 663,8 s con dos procesos simultáneos en una máquina de 12 CPU lógicas. Se detectaron 7 intervalos entre generaciones de más de 60 s (hasta 3 904 s en la generación 15 de la semilla 45), cuya causa no se estableció y que pueden incluir pausas del entorno; por eso la media por corrida (1 646 s con dominio) no describe el algoritmo. Las corridas sin intervalos anómalos tardaron entre 50 y 85 s con dominio y 78 s sin dominio (Tabla IV), del mismo orden que los cerca de 100 s por semilla de la RNA. Los tiempos no se usan para afirmar una ventaja de velocidad.

VI-D. Figuras

La Fig. 1 resume la comparación en PR-AUC, ROC-AUC y Recall@20 %, con la desviación estándar entre semillas como barra de error. Es la única figura de la suite completa disponible en el repositorio: las curvas que genera el *notebook* corresponden a su modo de humo (30 individuos, 3 generaciones) y no se incluyen.

VII. Impactos éticos y sociales

Correlación, no causalidad. Las variables de mayor peso en el árbol de referencia son tasas históricas de pérdida por dominio, instalación y marca. Un puntaje alto no indica que la instalación o el vendedor sean responsables; refleja el historial agregado de una categoría. El agente se plantea como apoyo a la priorización humana y nunca como mecanismo automático de sanción a instalaciones, vendedores o transportistas.

Sesgo heredado y artefactos de extracción. Si la base histórica contiene artefactos, el modelo los reproduce con apariencia de evidencia. El caso de `LG_REGION` ya demostró que una taxonomía puede codificar la etiqueta; la sospecha equivalente sobre `DOM_DOMAIN_ID` (seis valores con 100 % de pérdida y 200 a 834 filas cada uno en el conjunto completo; tres categorías grandes y puras con 1 507 filas, el 1,2 % del entrenamiento, en la auditoría de esta corrida) implica que el agente podría marcar sistemáticamente productos de ciertas categorías por un defecto de la extracción y no por un riesgo real. La interpretabilidad del GP ayuda: el peso del dominio es visible en la fórmula y la ablación lo cuantifica.

Tabla IV
CORRIDAS DE LA CONFIGURACIÓN ELEGIDA: ÁRBOL, UMBRAL, VALIDACIÓN Y PRUEBA POR SEMILLA

				PR-AUC	Prueba						Tiempo
Semilla	**Nodos**	**Altura**	**Umbral**	**val.**	**PR-AUC**	**ROC-AUC**	**Exhaust.**	**Precisión**	**F1**	**Recall@20 %**	**(s)**
Con `DOM_DOMAIN_ID` *(19 terminales)*											
42	9	4	0,825	0,6188	0,6258	0,7676	0,6445	0,5793	0,6101	0,4505	50
43	23	6	0,795	0,5935	0,5973	0,7676	0,7423	0,4878	0,5887	0,4132	66
44	36	8	1,134	**0,6818**	0,6887	0,8056	0,6775	0,5751	0,6221	0,4681	4 026
45	26	8	1,105	0,6291	0,6334	0,7688	0,6554	0,5587	0,6032	0,4488	4 004
46	9	4	0,555	0,6458	0,6512	0,7574	0,6462	0,5523	0,5956	0,4442	85
Sin `DOM_DOMAIN_ID` *(17 terminales)*											
42	7	3	0,295	0,5766	0,5797	0,7561	0,7751	0,4566	0,5747	0,4032	2 352
43	27	6	0,257	0,5816	0,5839	0,7572	0,7208	0,4823	0,5779	0,4057	2 410
44	26	7	0,136	0,5663	0,5707	0,7487	0,6765	0,4969	0,5730	0,3943	78
45	9	4	0,645	**0,5865**	0,5960	0,7703	0,6843	0,5198	0,5908	0,4099	246
46	36	8	0,868	0,5686	0,5531	0,7260	0,7525	0,4258	0,5438	0,3839	248

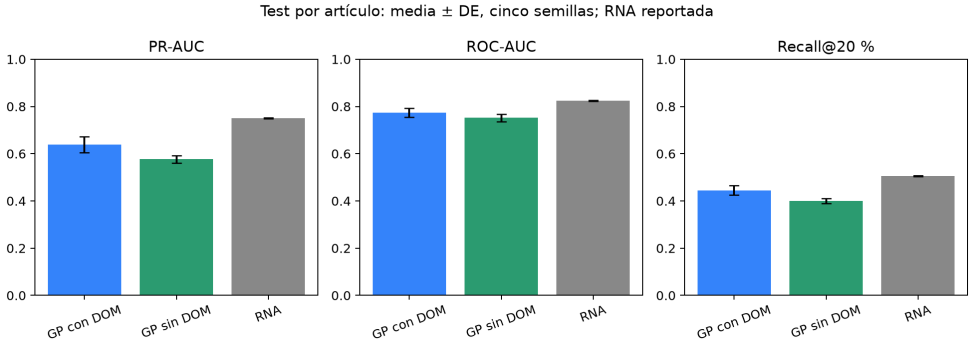


Figura 1. Comparación en el conjunto de prueba, por artículo: media y desviación estándar sobre cinco semillas del GP con y sin `DOM_DOMAIN_ID`, frente a la RNA reportada sobre el mismo mes de prueba.

Tabla V
MÉTRICAS EN EL CONJUNTO DE PRUEBA, MEDIA ± DESVIACIÓN ESTÁNDAR SOBRE CINCO SEMILLAS (MISMO HOLDOUT TEMPORAL)

Métrica	**GP**	**GP sin dominio**	**RNA**[a]
PR-AUC	0,6393 ± 0,0338	0,5767 ± 0,0160	0,7496 ± 0,0020
ROC-AUC	0,7734 ± 0,0186	0,7517 ± 0,0163	0,8241 ± 0,0020
Exhaustividad[b]	0,6732 ± 0,0408	0,7218 ± 0,0426	0,5339 ± 0,0136
Precisión[b]	0,5506 ± 0,0369	0,4763 ± 0,0364	0,7568 ± 0,0157
F1[b]	0,6039 ± 0,0129	0,5720 ± 0,0172	0,6259 ± 0,0044
Recall@1 %	0,0270 ± 0,0034	0,0246 ± 0,0001	0,0321 ± 0,0000
Recall@5 %	0,1343 ± 0,0127	0,1200 ± 0,0019	0,1581 ± 0,0006
Recall@10 %	0,2595 ± 0,0172	0,2257 ± 0,0063	0,3019 ± 0,0020
Recall@20 %	0,4450 ± 0,0199	0,3994 ± 0,0104	0,5060 ± 0,0024
Precision@1 %	0,8427 ± 0,1061	0,7668 ± 0,0021	1,0000 ± 0,0000
Precision@5 %	0,8387 ± 0,0796	0,7493 ± 0,0121	0,9873 ± 0,0038
Precision@10 %	0,8099 ± 0,0537	0,7043 ± 0,0198	0,9421 ± 0,0061
Precision@20 %	0,6944 ± 0,0311	0,6232 ± 0,0162	0,7895 ± 0,0037

[a] Cifras publicadas en el repositorio; la RNA no se reentrenó.
[b] RNA con umbral 0,5; GP con umbral de F1 óptimo en validación.

Esa transparencia obliga, no exime, a investigar el artefacto antes de operar.

Confidencialidad y efecto sobre la revisión. Los mapas de codificación contienen categorías, marcas e instalaciones de la empresa, por lo que los modelos entrenados se conservan solo localmente y se excluyen del paquete compartible; los archivos agregados no contienen identificadores de envío. Además, una lista priorizada concentra la atención en una fracción de los envíos: con Recall@20 % de 0,445, más de la mitad de las pérdidas quedarían fuera de la revisión, y el puntaje debe complementar, no sustituir, los controles existentes.

VIII. RESULTADOS Y CRITERIOS DE COMPARACIÓN

Desempeño predictivo. La RNA es superior en todas las métricas de orden: 0,110 más de PR-AUC y 0,051 más de ROC-AUC en media, diferencias que superan con holgura la dispersión entre semillas de ambos modelos. El GP sin dominio queda 0,173 por debajo en PR-AUC. El mejor árbol individual (semilla 44, PR-AUC 0,689) tampoco alcanza la peor semilla de la RNA.

Calidad de la priorización. El GP captura menos pérdidas en cada fracción revisada (Recall@20 % de 0,445 frente a 0,506) y con menos precisión en la cima (Precision@10 % de 0,810 frente a 0,942). Sin embargo, la Precision@1 % perfecta de la RNA, que el GP reproduce solo en la semilla 46, es justamente la cifra bajo sospecha por el artefacto de dominio; la ventaja de la RNA en la cima podría estar inflada por la misma variable que el GP pondera con el mayor coeficiente.

Interpretabilidad. Es el criterio en el que el GP gana sin discusión. Los modelos finales tienen entre 7 y 36 nodos (media 20,6 ± 11,6 con dominio); el de referencia se reduce

a una suma ponderada de siete terminales y el de la ablación a una regla lineal de cinco. Un revisor puede leer por qué un envío quedó arriba; la RNA, un ensamble de dos redes con *embeddings*, solo ofrece importancias por permutación a posteriori. Debe matizarse que los terminales son variables transformadas (tasas históricas y frecuencias aprendidas en entrenamiento), no las columnas crudas: la fórmula es legible, pero no es una ecuación directa sobre pesos y montos.

Costo computacional. Sin los intervalos anómalos, una corrida del GP tarda entre 50 y 85 s en CPU, comparable con la RNA; el GP no requiere GPU ni la pila de AutoGluon, pero el cribado añadió seis corridas. Ninguna técnica tiene una ventaja de velocidad demostrada.

Estabilidad entre semillas. La RNA es muy estable (desviación de PR-AUC de 0,0020); el GP varía 0,0338 con dominio y 0,0160 sin él, y sus árboles cambian de forma y tamaño entre semillas (de 9 a 36 nodos). La búsqueda con 180 individuos y 25 generaciones no converge a una misma solución, lo que es esperable en regresión simbólica y exige reportar varias semillas.

Dependencia de `DOM_DOMAIN_ID`. Ambos modelos dependen del dominio: es la variable más importante de la RNA (caída de PR-AUC de 0,197 al permutarla [11]) y la de mayor coeficiente en el árbol de referencia; su ablación en el GP cuesta 0,0626 de PR-AUC. La ablación muestra dependencia, no causalidad, y no prueba la ausencia de otros artefactos: categorías correlacionadas pueden conservar una señal similar.

IX. Conclusiones y trabajo futuro

Un clasificador simbólico evolucionado con programación genética, entrenado solo con información disponible al crear el envío y bajo el mismo protocolo temporal que la red neuronal, ordena el riesgo de pérdida de forma útil (PR-AUC de 0,639 $\pm$ 0,034 frente a 0,312 del azar; ROC-AUC de 0,773 $\pm$ 0,019) pero no alcanza a la RNA (0,750 y 0,824) en ningún criterio de desempeño. A cambio ofrece un modelo de decenas de nodos que puede leerse y auditarse, y que hace explícita la dependencia de la variable de dominio que en la RNA solo se infiere por permutación. La respuesta a la pregunta del módulo es parcial: el GP es interpretable, pero no competitivo en precisión con la configuración y el presupuesto evaluados.

El resultado más valioso vuelve a ser metodológico. Mantener la selección de configuración, árbol y umbral exclusivamente en validación, sellarla antes de puntuar la prueba, repetir cinco semillas y validar de forma independiente que las etiquetas y las columnas de fuga no alteran los puntajes permite afirmar que la brecha con la RNA es real y no un artefacto de la evaluación. La mejora frente a la prueba inicial del GP (PR-AUC 0,548, una semilla) cambió a la vez codificación, presupuesto y filas de aptitud, y no es atribuible a una sola técnica.

El trabajo futuro inmediato es auditar `DOM_DOMAIN_ID` en la fuente, pues condiciona a ambos modelos; ampliar la búsqueda de hiperparámetros del GP con más semillas por configuración y presupuestos mayores, cuyo límite no se alcanzó; probar primitivas condicionales y una aptitud multiobjetivo que explicite el compromiso entre PR-AUC y tamaño; evaluar la disponibilidad real de las etiquetas históricas que asume la codificación temporal; y agregar métricas a nivel de envío y meses de prueba adicionales, lo que requiere una nueva extracción homogénea. Las técnicas restantes del proyecto, inferencia difusa y métodos de ensamble, se evaluarán con este mismo protocolo; un ensamble que combine la RNA con el árbol simbólico es un candidato natural para unir desempeño e interpretabilidad.

Referencias

[1] MercadoLibre, Inc., "Annual Report on Form 10-K for the fiscal year ended December 31, 2025," U.S. Securities and Exchange Commission, 25 feb. 2026.

[2] M. Bortolini *et al.*, "A deep learning approach to predict supply chain delivery delay risk based on macroeconomic indicators: A case study in the automotive sector," *Applied Sciences*, vol. 14, no. 11, art. 4688, 2024, doi: 10.3390/app14114688.

[3] N. Nezamoddini, A. Gholami y F. Aqlan, "A risk-based optimization framework for integrated supply chains using genetic algorithm and artificial neural networks," *Int. J. Production Economics*, art. 107569, 2020, doi: 10.1016/j.ijpe.2019.107569.

[4] V. Gajović, M. Kerkez y J. Kočović, "Modeling and simulation of logistic processes: Risk assessment with a fuzzy logic technique," *Simulation*, vol. 94, no. 6, 2018, doi: 10.1177/0037549717738351.

[5] "Delay prediction to mitigate e-commerce supplier disruptions using voting mechanism," *IFAC-PapersOnLine*, vol. 55, no. 10, pp. 731–736, 2022, doi: 10.1016/j.ifacol.2022.09.495.

[6] F. Aqlan y S. S. Lam, "A fuzzy-based integrated framework for supply chain risk assessment," *Int. J. Production Economics*, vol. 161, pp. 54–63, 2015, doi: 10.1016/j.ijpe.2014.11.013.

[7] B. Ye, J. Zuo, X. Zhao y L. Luo, "Research on the express delivery delay prediction based on neural network in the background of big data," en *Proc. 6th Int. Conf. Electronic, Mechanical, Information and Management Society*, 2016, pp. 1449–1454, doi: 10.2991/emim-16.2016.294.

[8] J. R. Koza, *Genetic Programming: On the Programming of Computers by Means of Natural Selection*. Cambridge, MA, EE. UU.: MIT Press, 1992.

[9] F.-A. Fortin, F.-M. De Rainville, M.-A. Gardner, M. Parizeau y C. Gagné, "DEAP: Evolutionary algorithms made easy," *J. Machine Learning Research*, vol. 13, pp. 2171–2175, 2012.

[10] T. Saito y M. Rehmsmeier, "The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets," *PLoS ONE*, vol. 10, no. 3, art. e0118432, 2015.

[11] K. Bueno S. y L. Portela L., "RiskShip: Priorización inteligente de envíos con riesgo de falla. Solución con redes neuronales," informe de proyecto, Pontificia Universidad Javeriana, Bogotá, 2026.

[12] P. G. Espejo, S. Ventura y F. Herrera, "A survey on the application of genetic programming to classification," *IEEE Trans. Syst., Man, Cybern. C, Appl. Rev.*, vol. 40, no. 2, pp. 121–144, 2010, doi: 10.1109/TSMCC.2009.2033566.

[13] U. Bhowan, M. Johnston y M. Zhang, "Developing new fitness functions in genetic programming for classification with unbalanced data," *IEEE Trans. Syst., Man, Cybern. B, Cybern.*, vol. 42, no. 2, pp. 406–421, 2012, doi: 10.1109/TSMCB.2011.2167144.

[14] U. Bhowan, M. Johnston, M. Zhang y X. Yao, "Evolving diverse ensembles using genetic programming for classification with unbalanced data," *IEEE Trans. Evol. Comput.*, vol. 17, no. 3, pp. 368–386, 2013, doi: 10.1109/TEVC.2012.2199119.

[15] S. Luke y L. Panait, "A comparison of bloat control methods for genetic programming," *Evolutionary Computation*, vol. 14, no. 3, pp. 309–344, 2006, doi: 10.1162/evco.2006.14.3.309.

[16] R. Poli, W. B. Langdon y N. F. McPhee, *A Field Guide to Genetic Programming*. Lulu.com, 2008, ISBN 978-1-4092-0073-4.

[17] C. Rudin, “Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead,” *Nature Machine Intelligence*, vol. 1, no. 5, pp. 206–215, 2019, doi: 10.1038/s42256-019-0048-x.

[18] W. La Cava *et al.*, “Contemporary symbolic regression methods and their relative performance,” en *Proc. NeurIPS Datasets and Benchmarks Track*, 2021, doi: 10.48550/arXiv.2107.14351.

[19] L. Grinsztajn, E. Oyallon y G. Varoquaux, “Why do tree-based models still outperform deep learning on typical tabular data?,” en *Advances in Neural Information Processing Systems*, vol. 35, 2022, doi: 10.48550/arXiv.2207.08815.

[20] R. Shwartz-Ziv y A. Armon, “Tabular data: Deep learning is not all you need,” *Information Fusion*, vol. 81, pp. 84–90, 2022, doi: 10.1016/j.inffus.2021.11.011.

[21] J. Davis y M. Goadrich, “The relationship between precision-recall and ROC curves,” en *Proc. 23rd Int. Conf. Machine Learning (ICML)*, 2006, pp. 233–240, doi: 10.1145/1143844.1143874.

[22] S. Kaufman, S. Rosset, C. Perlich y O. Stitelman, “Leakage in data mining: Formulation, detection, and avoidance,” *ACM Trans. Knowl. Discov. Data*, vol. 6, no. 4, art. 15, pp. 1–21, 2012, doi: 10.1145/2382577.2382579.

[23] J. de Leeuw, Z. Bukhsh y Y. Zhang, “Parcel loss prediction in last-mile delivery: Deep and non-deep approaches with insights from explainable AI,” preimpresión arXiv:2310.16602, 2023, doi: 10.48550/arXiv.2310.16602.

[24] Y. Zhang, Y. Wang y Y. Wang, “A deep tabular learning framework for e-commerce delivery delay prediction and cost-sensitive operational risk mitigation,” *Algorithms*, vol. 19, no. 7, art. 597, 2026, doi: 10.3390/a19070597.

[25] M. Lunet, D. Fernandes, F. Neves-Moreira y P. Amorim, “Symbolic pricing policies for attended home delivery – the case of an online retailer,” en *Proc. Genetic and Evolutionary Computation Conf. (GECCO)*, 2025, pp. 1397–1405, doi: 10.1145/3712256.3726361.